

Movilidad Urbana usando datos de telefonía: desafíos en HPC y Big Data

Oscar Peredo A.
Investigador

Telefónica I+D Chile
20 de Enero de 2016

CONTENIDOS

Centro I+D - Chile

- ▶ Estado del arte
- ▶ Trazas de eventos y antenas
- ▶ Aplicaciones
- ▶ Desafíos en HPC y Big Data
- ▶ Cooperación: MAMUT

CONTENIDOS

Centro I+D - Chile

- ▶ Estado del arte
- ▶ Trazas de eventos y antenas
- ▶ Aplicaciones
- ▶ Desafíos en HPC y Big Data
- ▶ Cooperación: MAMUT

Centro I+D Telefónica

- ▶ Centro co-financiado por CORFO, recién 1 año de vida
- ▶ Telefónica I+D tiene oficinas en Barcelona, Granada, Huesca, Londres, Madrid, Sao Paulo, Tel Aviv, Valladolid y ahora Santiago de Chile
- ▶ Operadora telefónica: Movistar
- ▶ Nuevos mercados: Minería, Agro y Ciudades
 - Internet de las Cosas, M2M
 - Big Data (¿y HPC?)
 - Investigación aplicada
 - Desarrollo de software y hardware
 - Dinamizar el ecosistema (universidades, centros de investigación, etc.)

Call Detail Records

- ▶ Logs de facturación en telefonía (datos, voz, sms,...)
- ▶ Campos de interés en datos y voz:
 - número origen
 - número destino (sólo para voz)
 - fecha
 - hora
 - identificador de antena de origen
- ▶ Carga diaria no comprimida ni serializada entre 20 y 40 GB (18 meses se almacenan para facturación ~ 16 TB)
- ▶ Datos no estructurados (campos vacíos, con diferentes formatos y convenciones)

Estado del arte: CDRs para movilidad urbana

Limits of Predictability in Human Mobility

Chaoming Song,^{1,2} Zehui Qu,^{1,2,3} Nicholas Blumm,^{1,2} Albert-László Barabási^{1,2*}

A range of applications, from predicting the spread of human and electronic viruses to city planning and resource management in mobile communications, depend on our ability to foresee the whereabouts and mobility of individuals, raising a fundamental question: To what degree is human behavior predictable? Here we explore the limits of predictability in human dynamics by studying the mobility patterns of anonymized mobile phone users. By measuring the entropy of each individual's trajectory, we find a 93% potential predictability in user mobility across the whole user base. Despite the significant differences in the travel patterns, we find a remarkable lack of variability in predictability, which is largely independent of the distance users cover on a regular basis.



Origin–destination trips by purpose and time of day inferred from mobile phone data

Lauren Alexander^{a,*}, Shan Jiang^b, Mikel Murga^a, Marta C. González^a

^aDepartment of Civil and Environmental Engineering, Massachusetts Institute of Technology, Cambridge, MA, United States

^bDepartment of Urban Studies and Planning, Massachusetts Institute of Technology, Cambridge, MA, United States

The dynamics of a mobile phone network

Cesar A. Hidalgo^{a,*}, C. Rodriguez-Sickert^b

^aCenter for Complex Network Research, Department of Physics, University of Notre Dame, United States

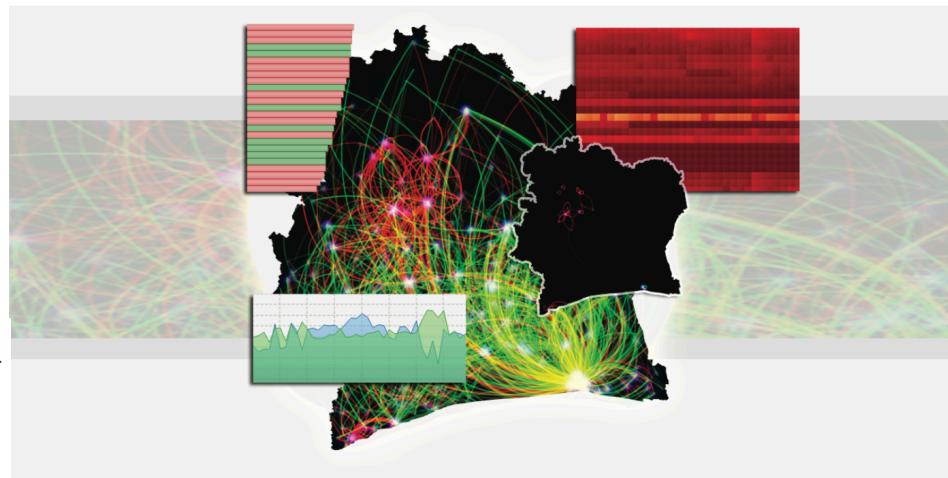
^bDepartment of Sociology, Pontificia Universidad Católica de Chile, Chile

Received 22 October 2007; received in revised form 7 January 2008

Available online 18 January 2008

Exploration and Analysis of Massive Mobile Phone Data: A Layered Visual Analytics approach

Stef van den Elzen, Jorik Blaas, Danny Holten, Jan-Kees Buenen, Jarke J. van Wijk, Robert Spousta, Anna Miao, Simone Sala, Steve Chan



CONTENIDOS

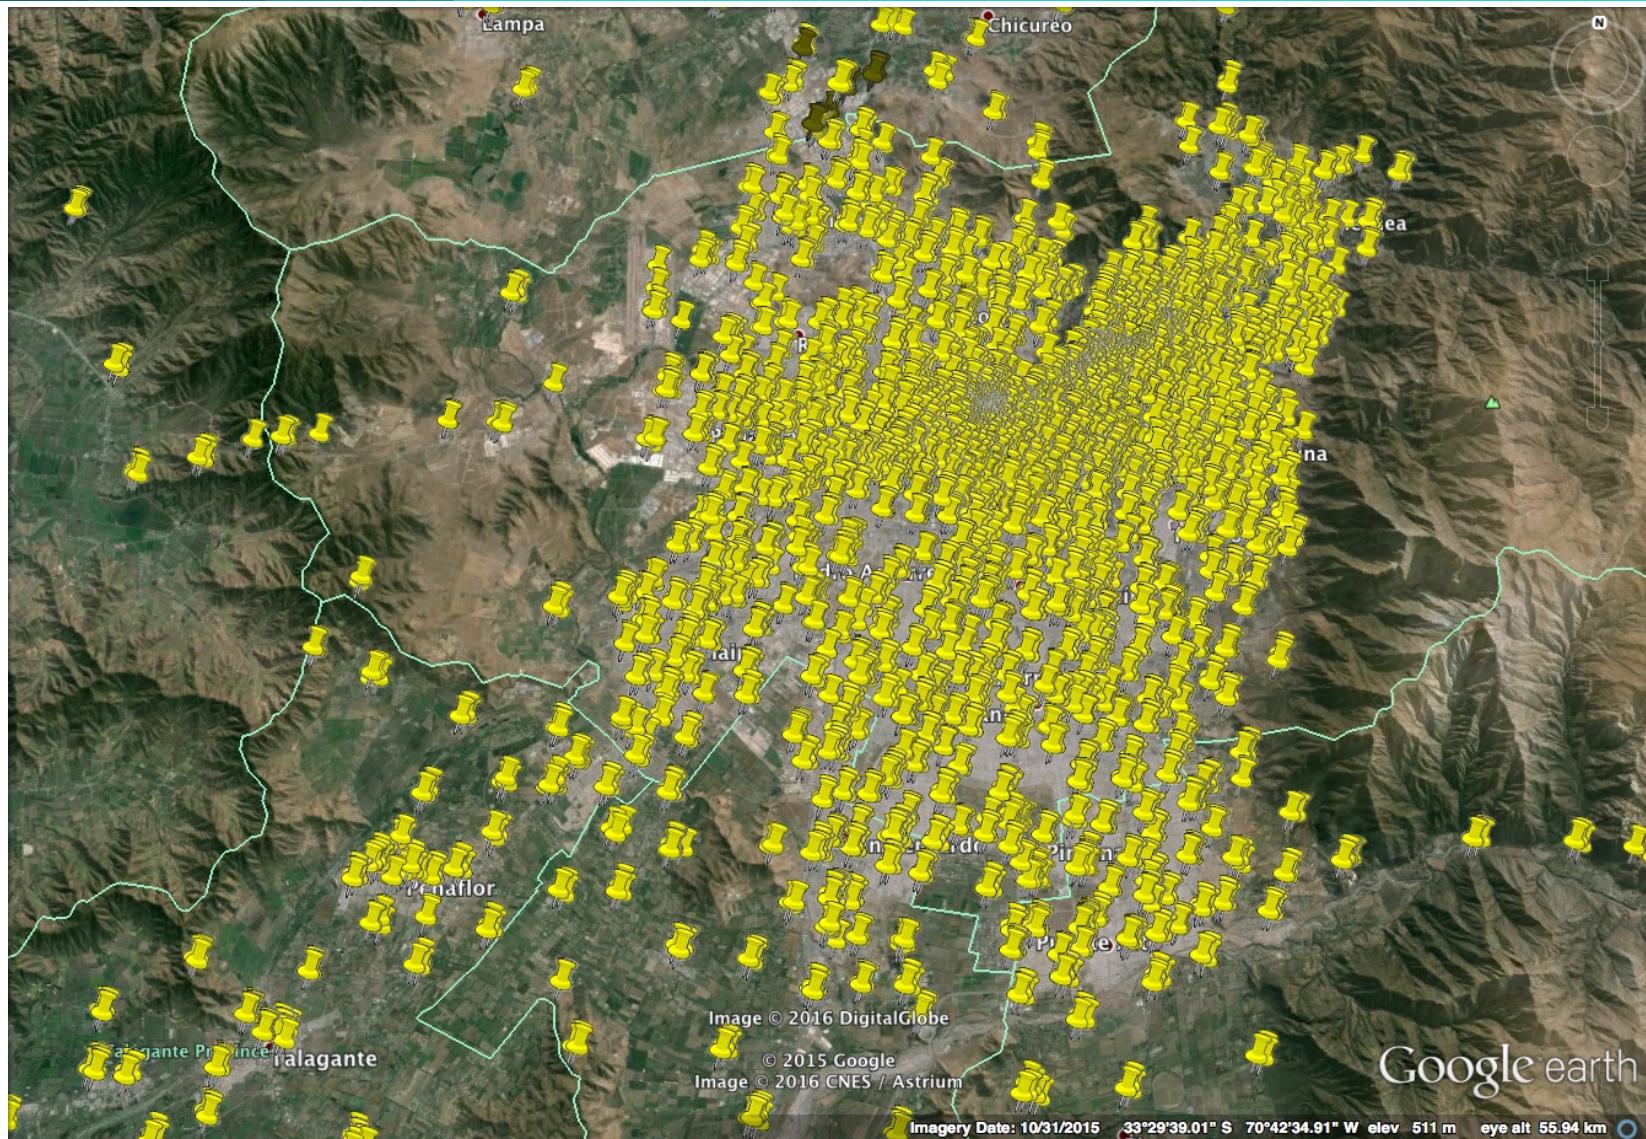
Centro I+D - Chile

- ▶ Estado del arte
- ▶ Trazas de eventos y antenas
- ▶ Aplicaciones
- ▶ Desafíos en HPC y Big Data
- ▶ Cooperación: MAMUT

Antenas (movistar)



Antenas (movistar)

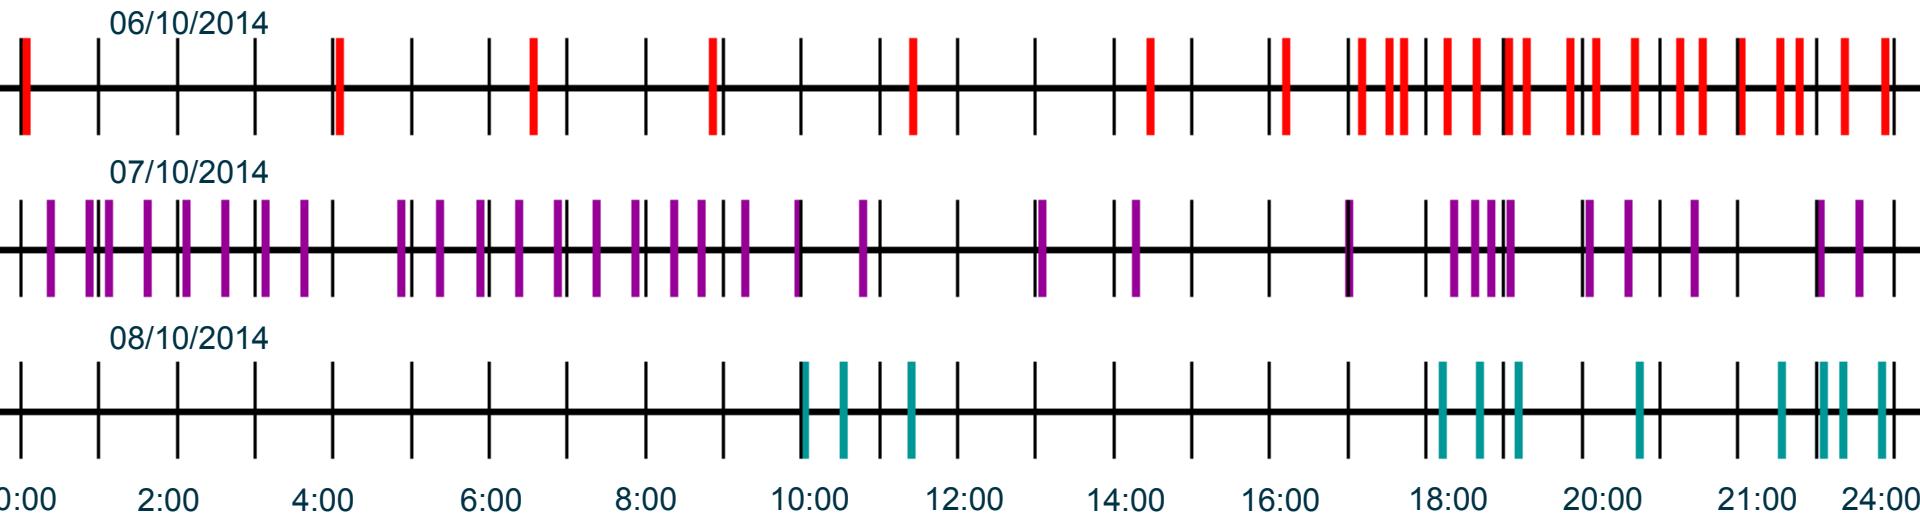


Antenas (movistar)



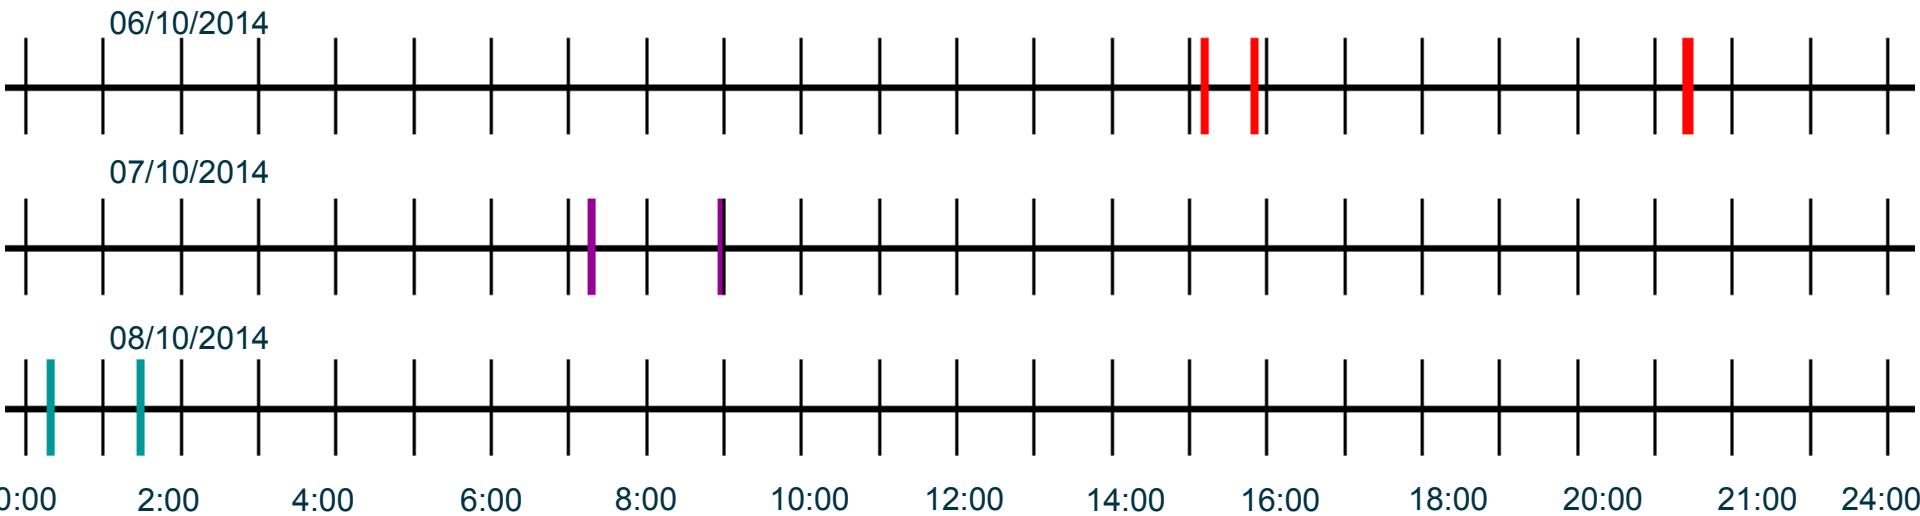
Trazas de eventos para tráfico de datos

- ▶ Ejemplo de trazas para un único dispositivo de Santiago:

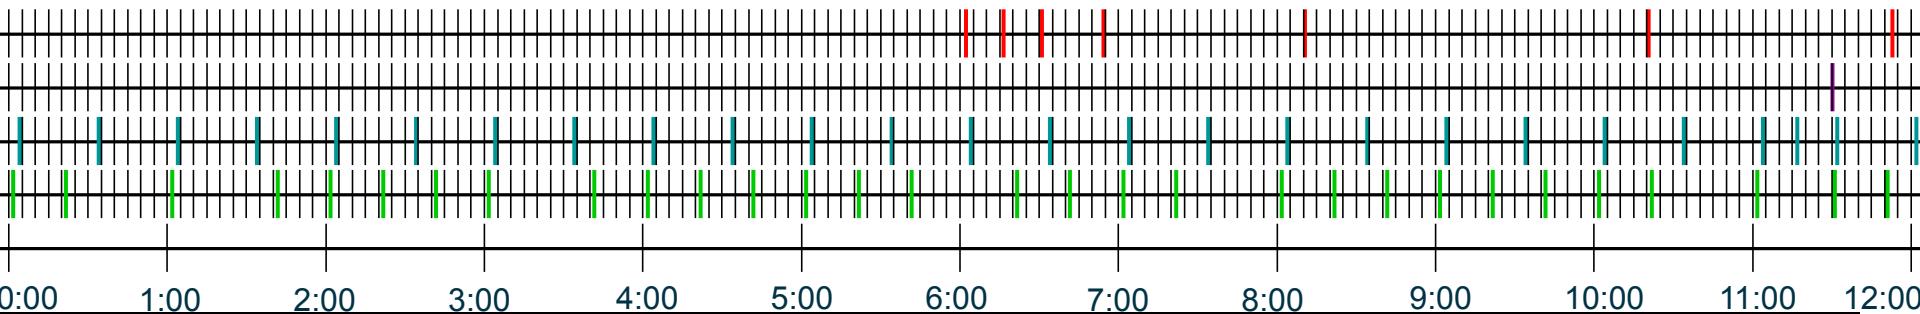


Trazas de eventos para tráfico de voz

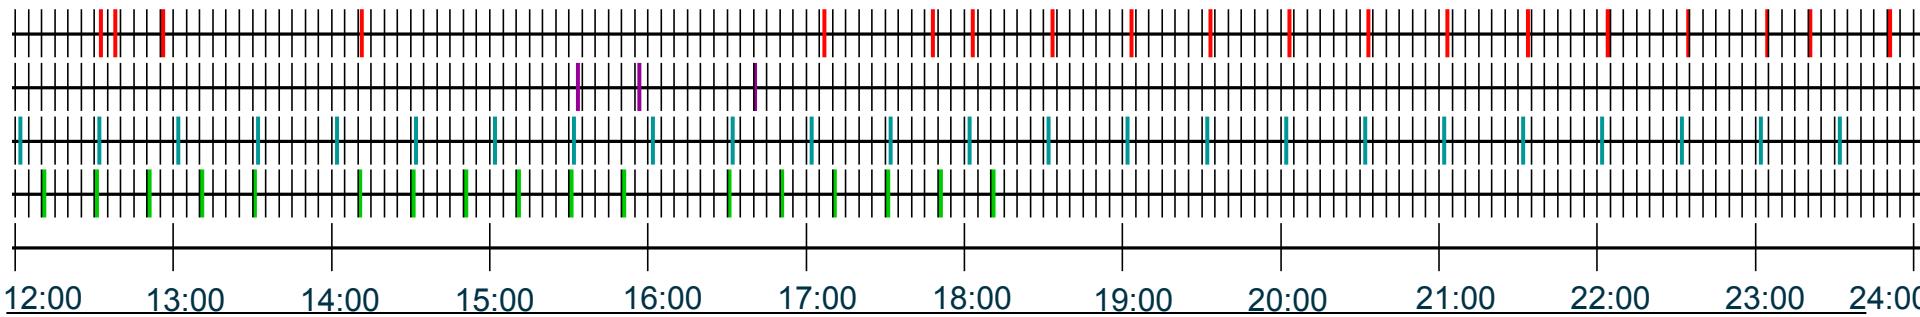
- ▶ Ejemplo de trazas para un único dispositivo de Santiago:



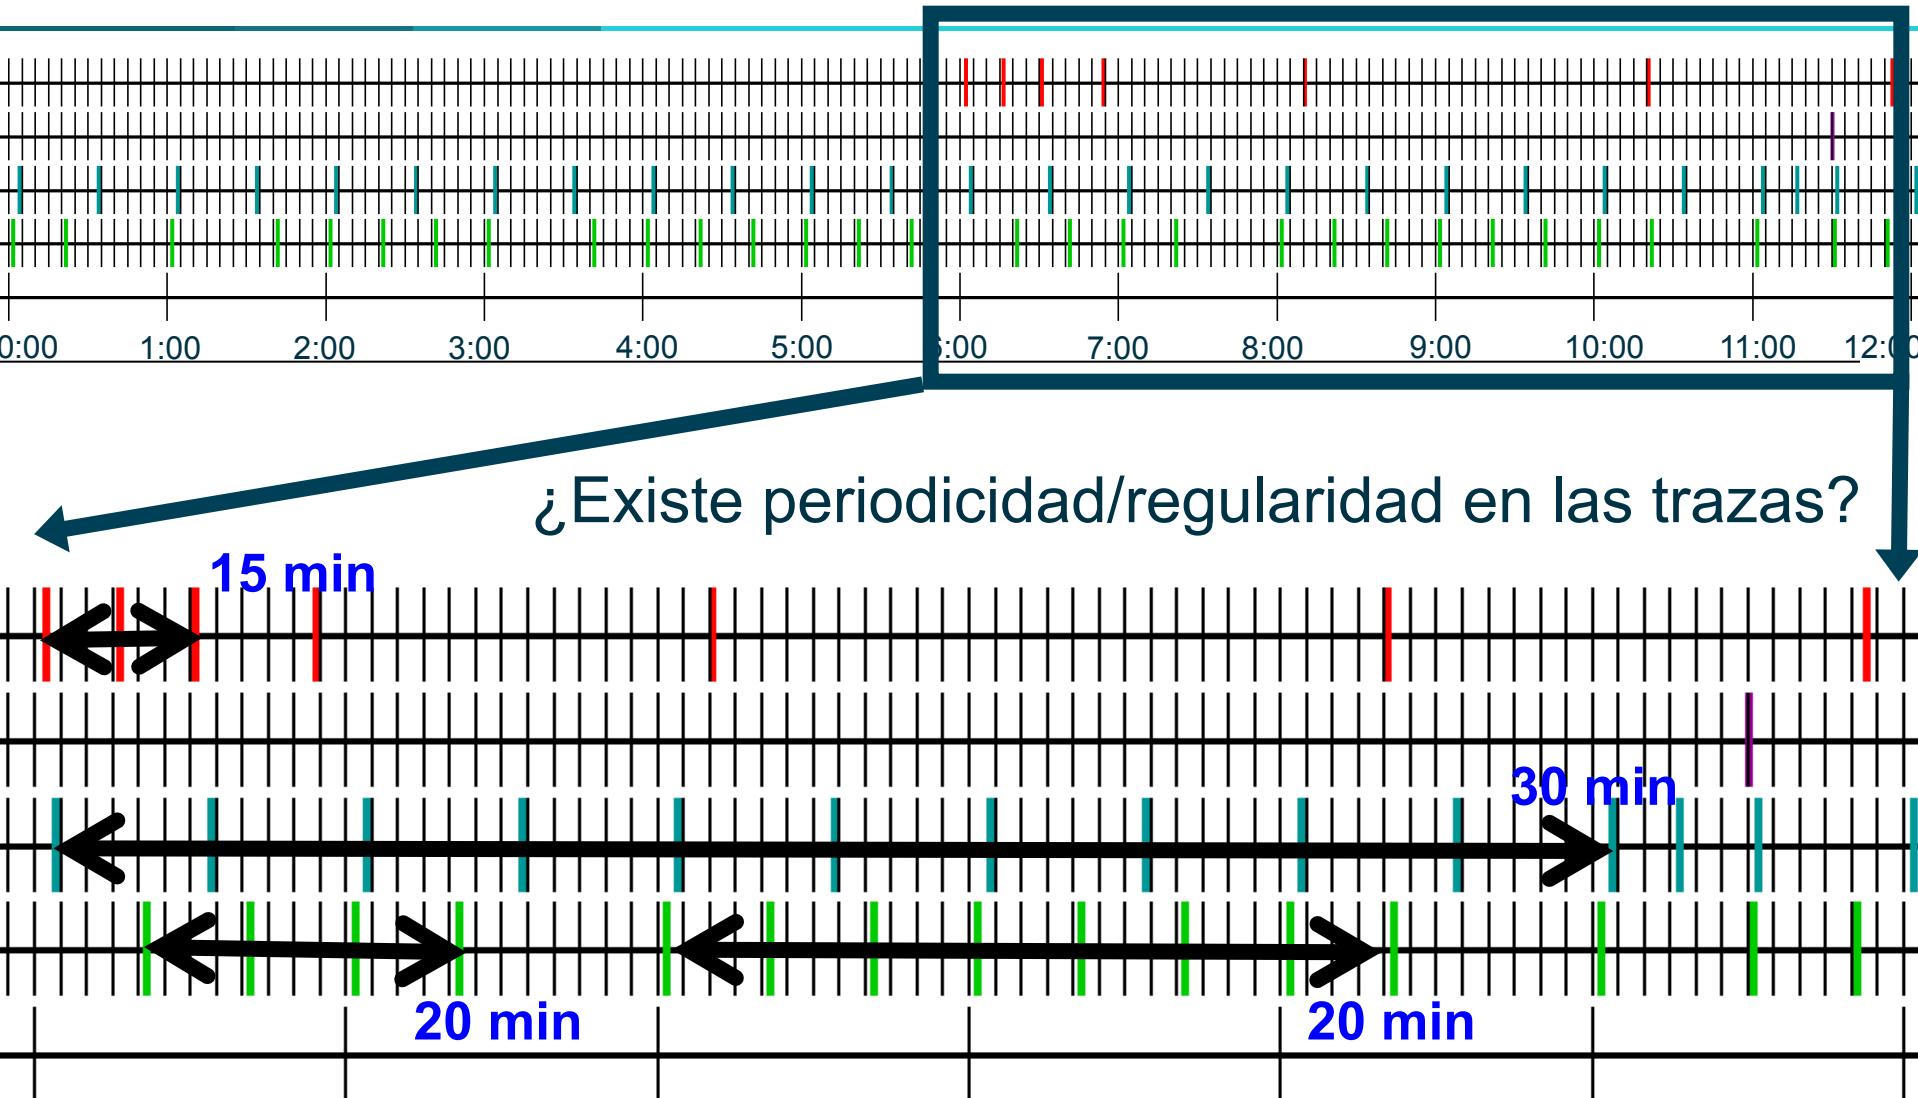
Trazas de eventos: ¿periodicidad?



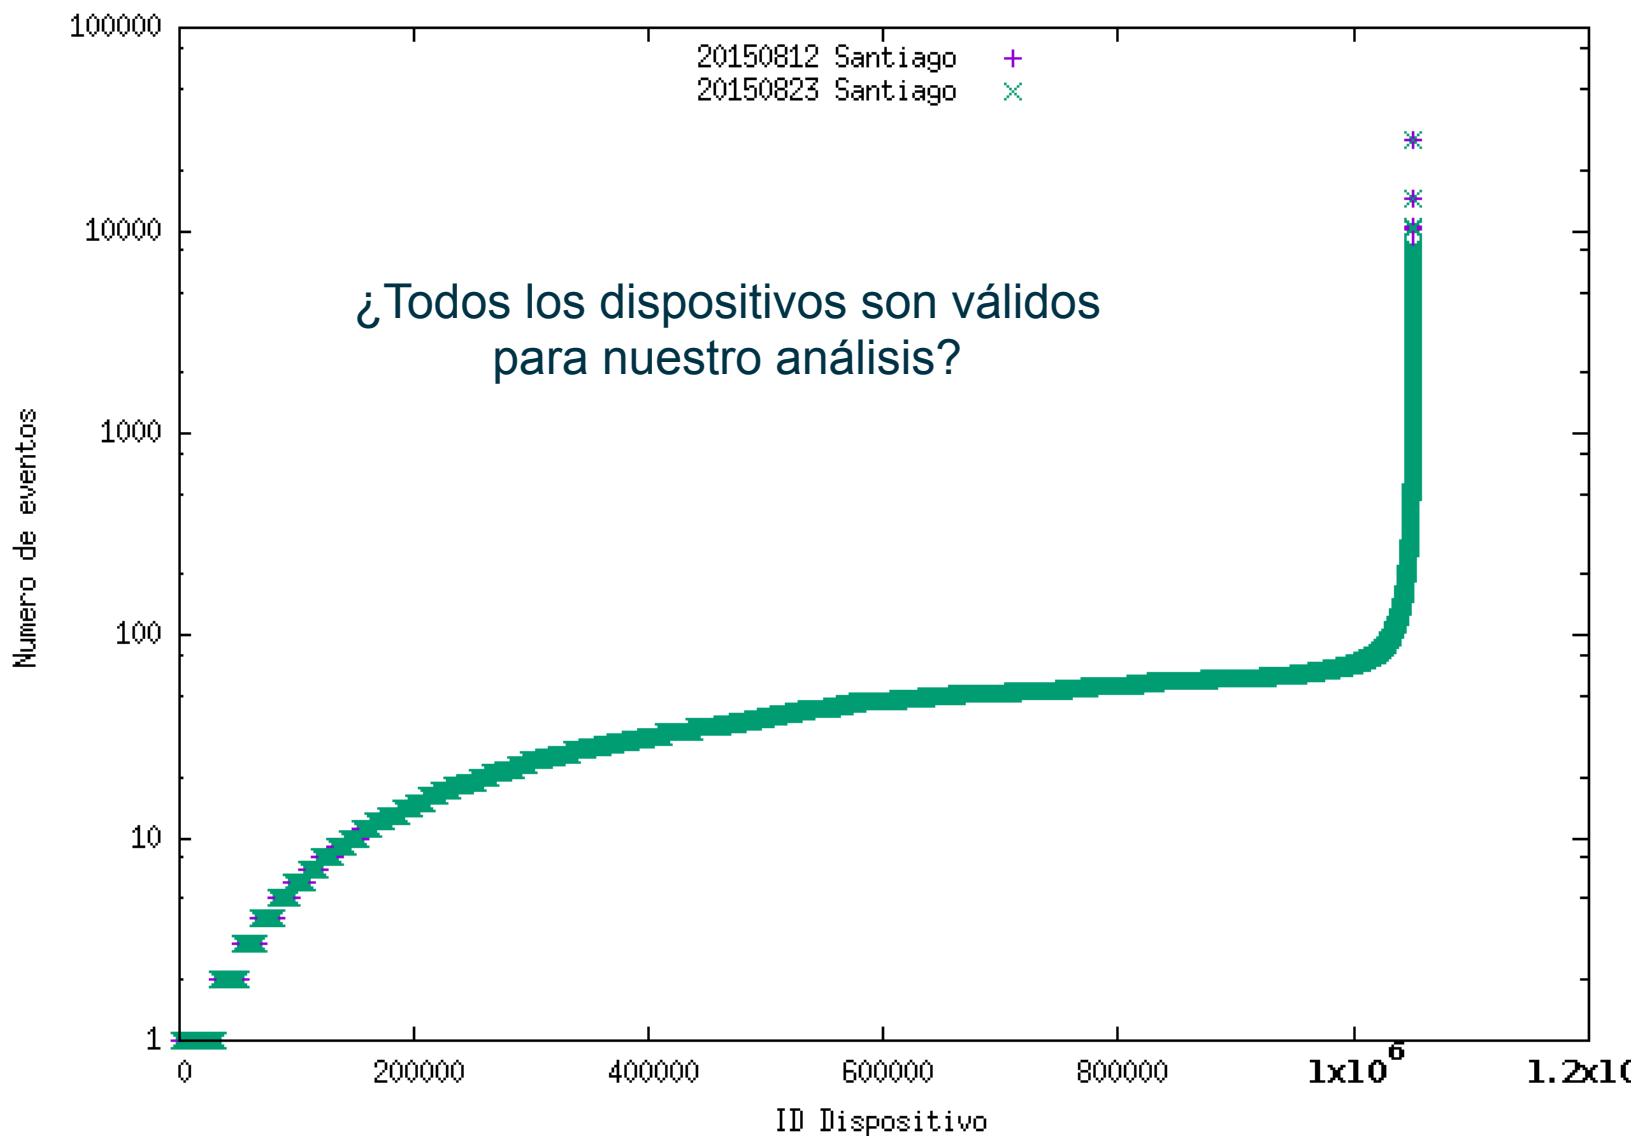
4 trazas de eventos en un día para diferentes dispositivos
0:00-24:00



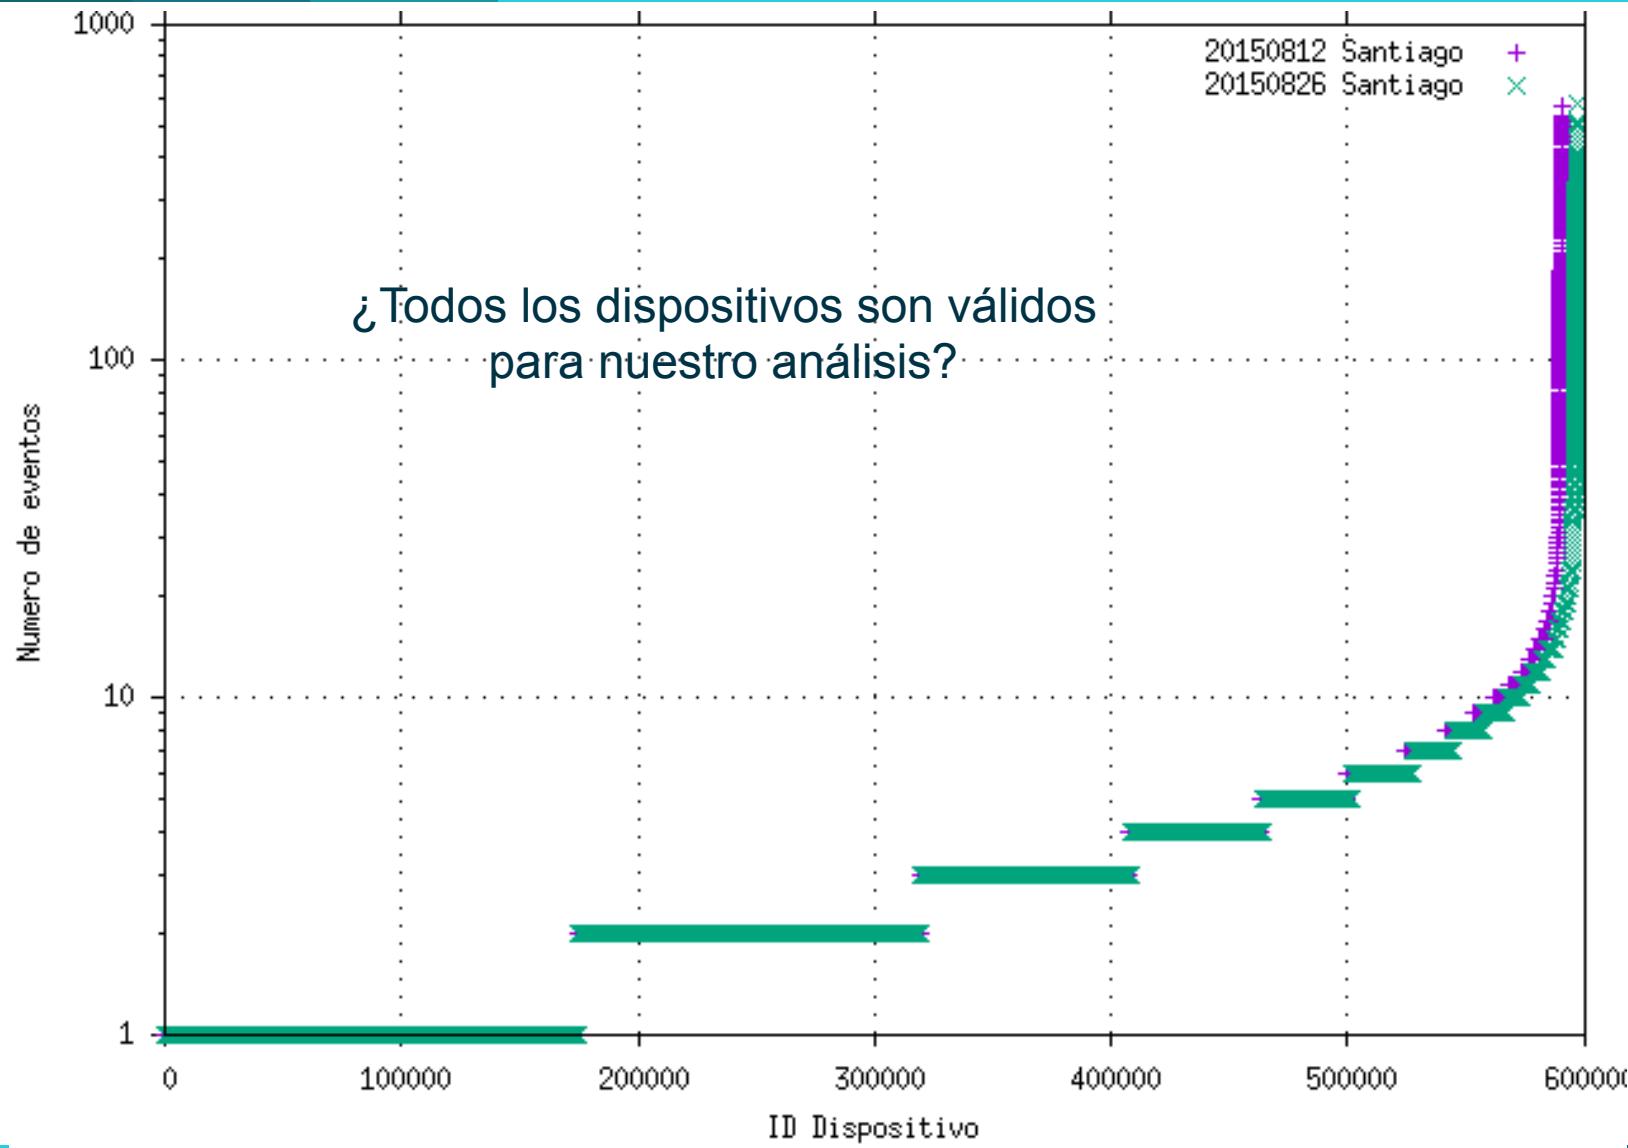
Trazas de eventos: ¿periodicidad?



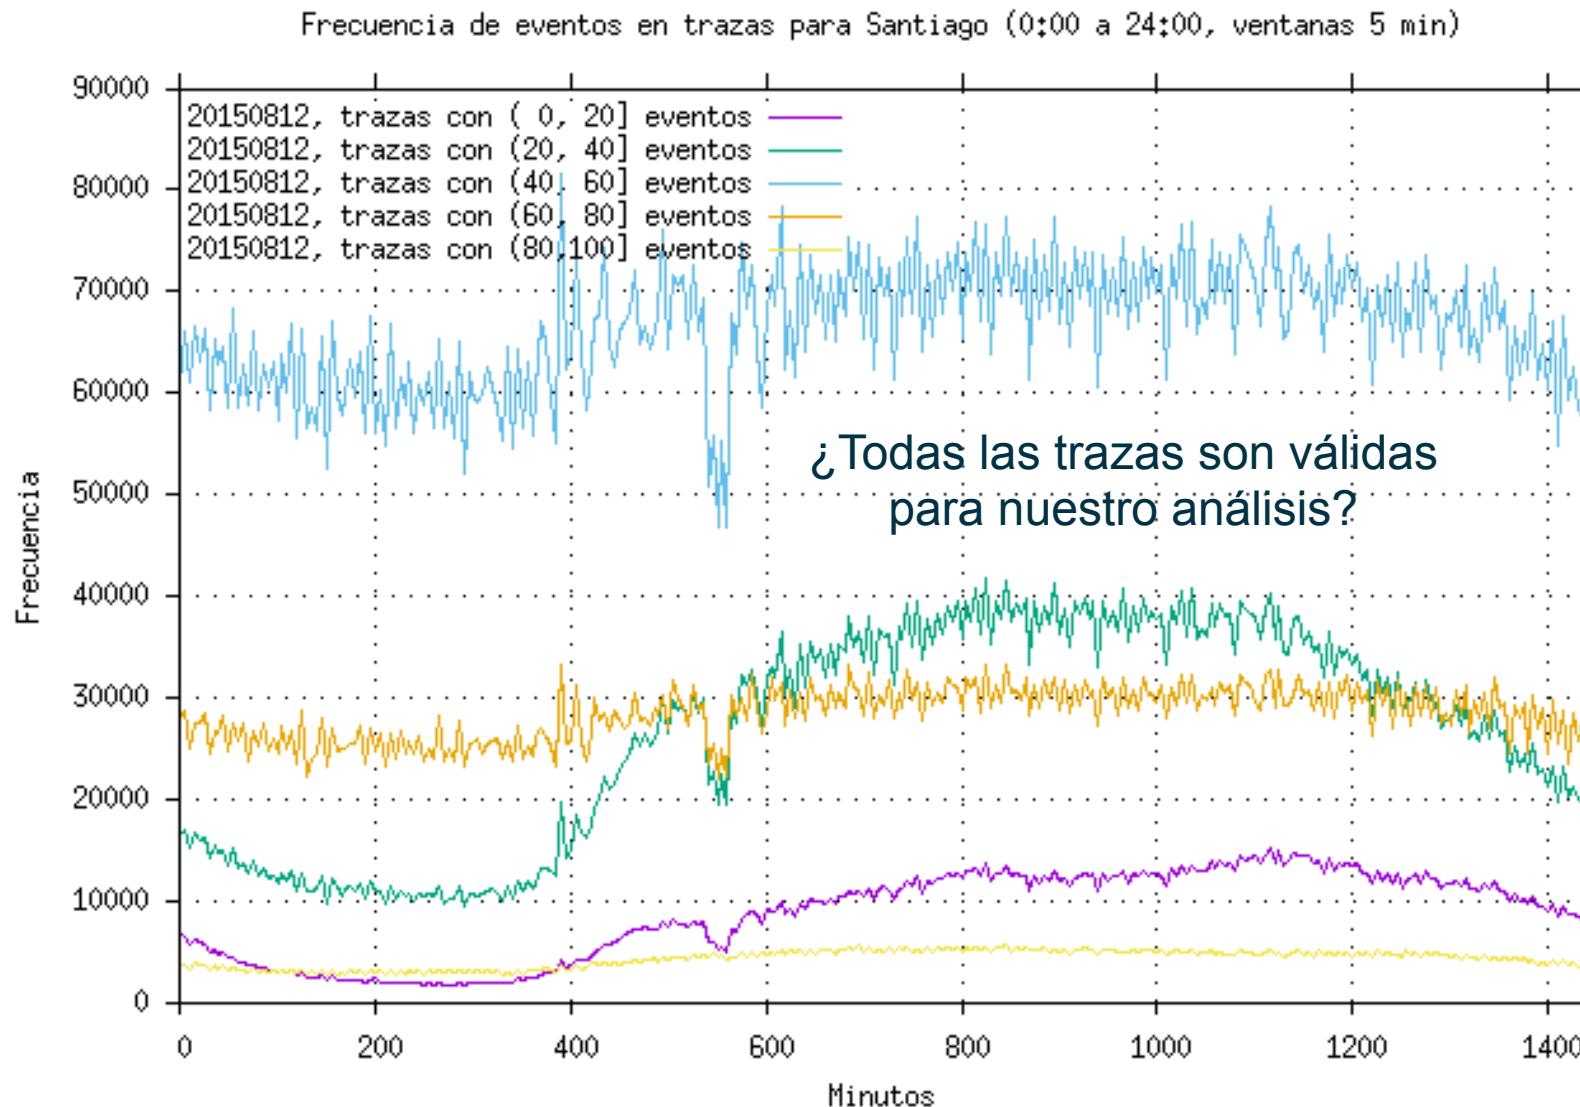
#Eventos_datos/Dispositivo



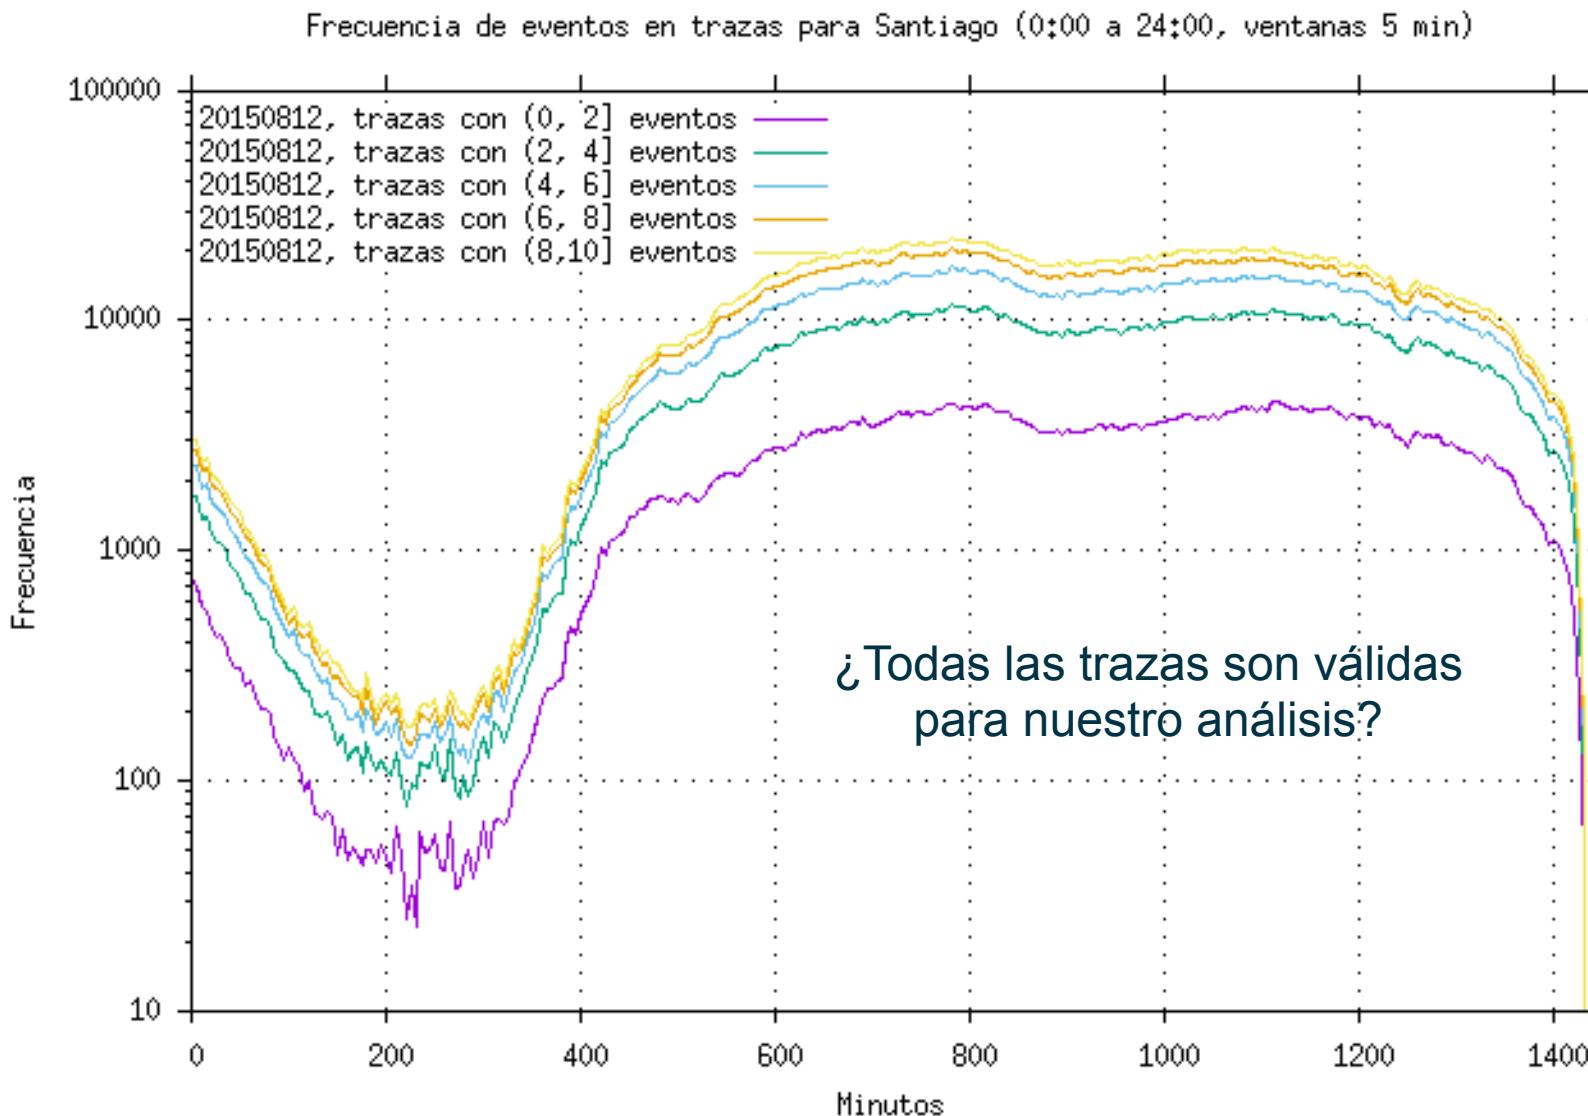
#Eventos_voz/Dispositivo



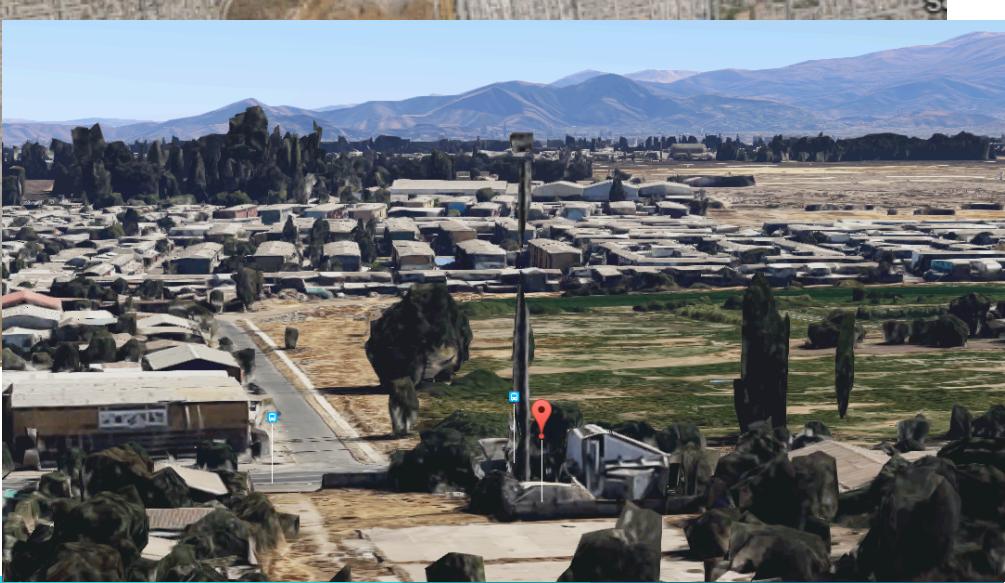
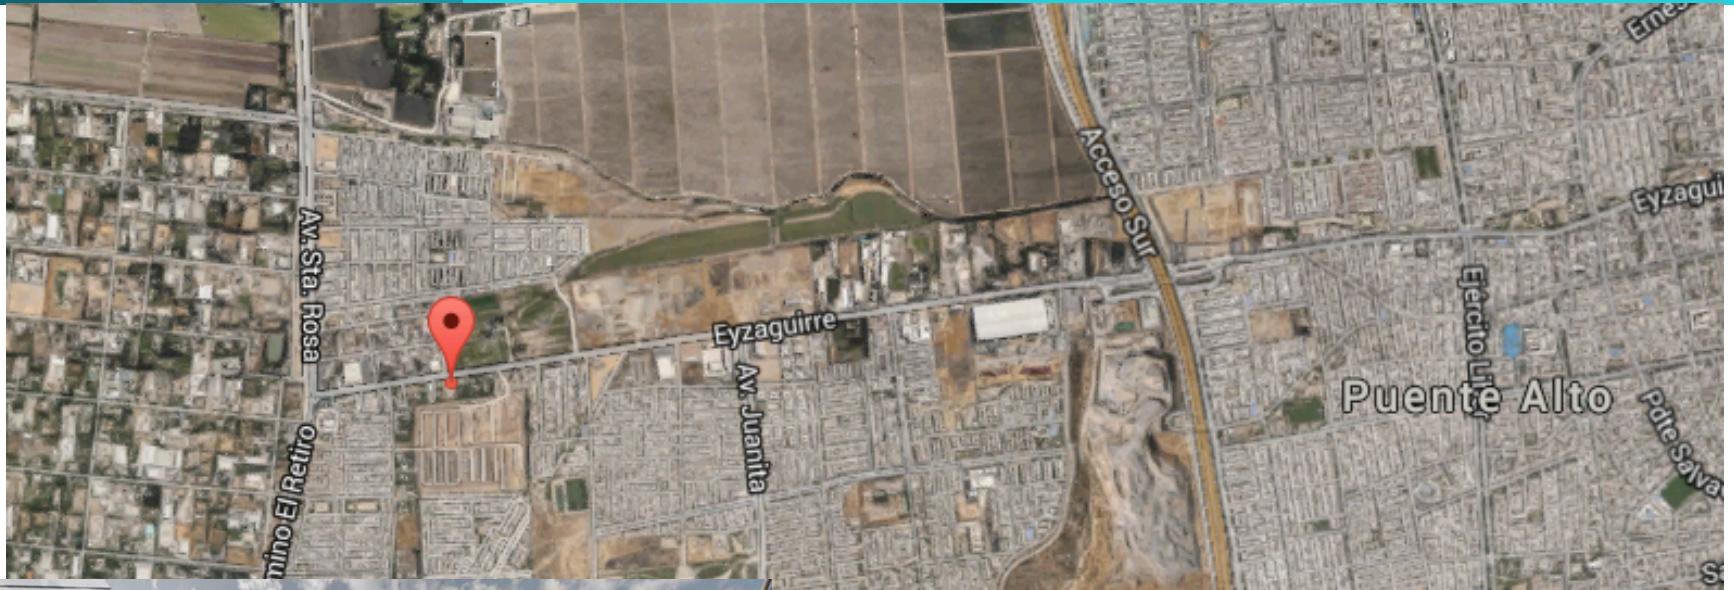
#Eventos_datos/Minuto



#Eventos_voz/Minuto



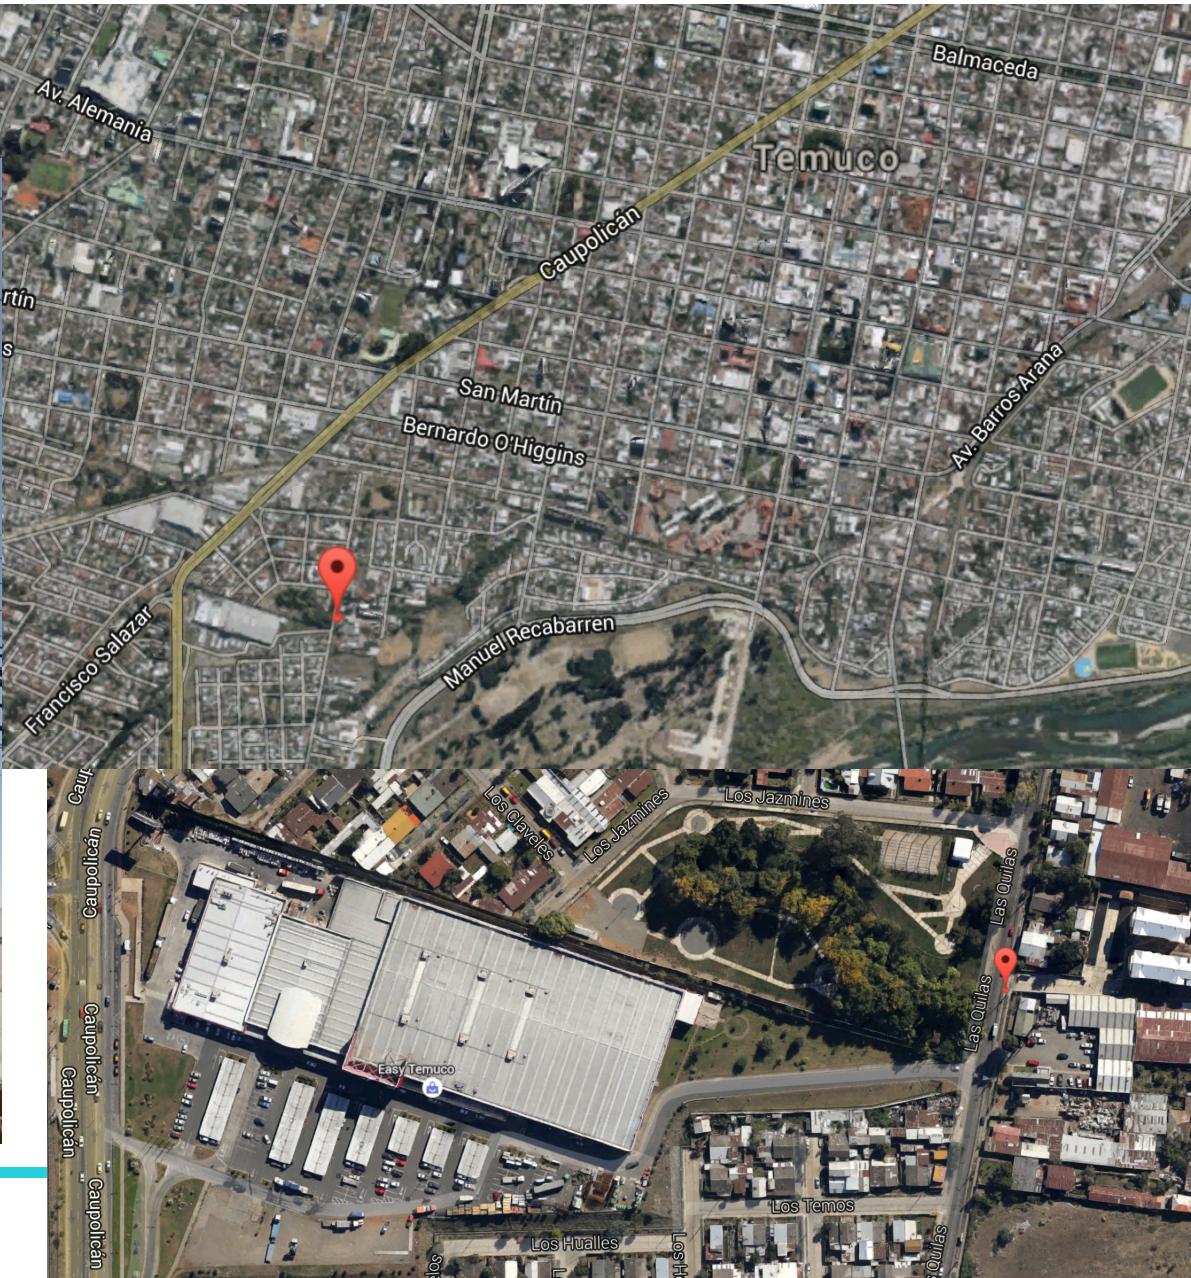
Curiosidades



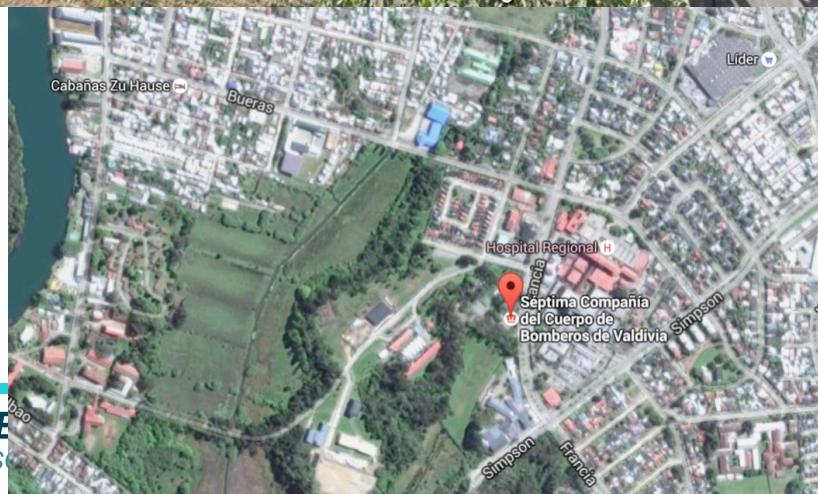
Curiosidades



Curiosidades



Curiosidades



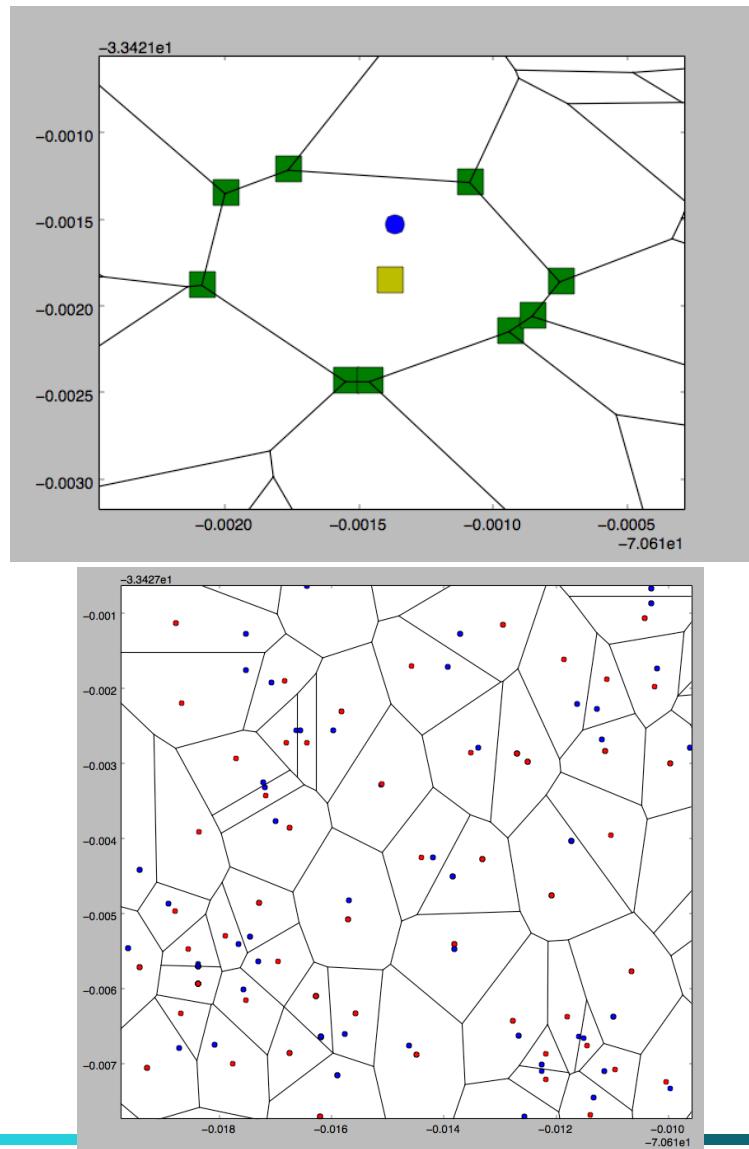
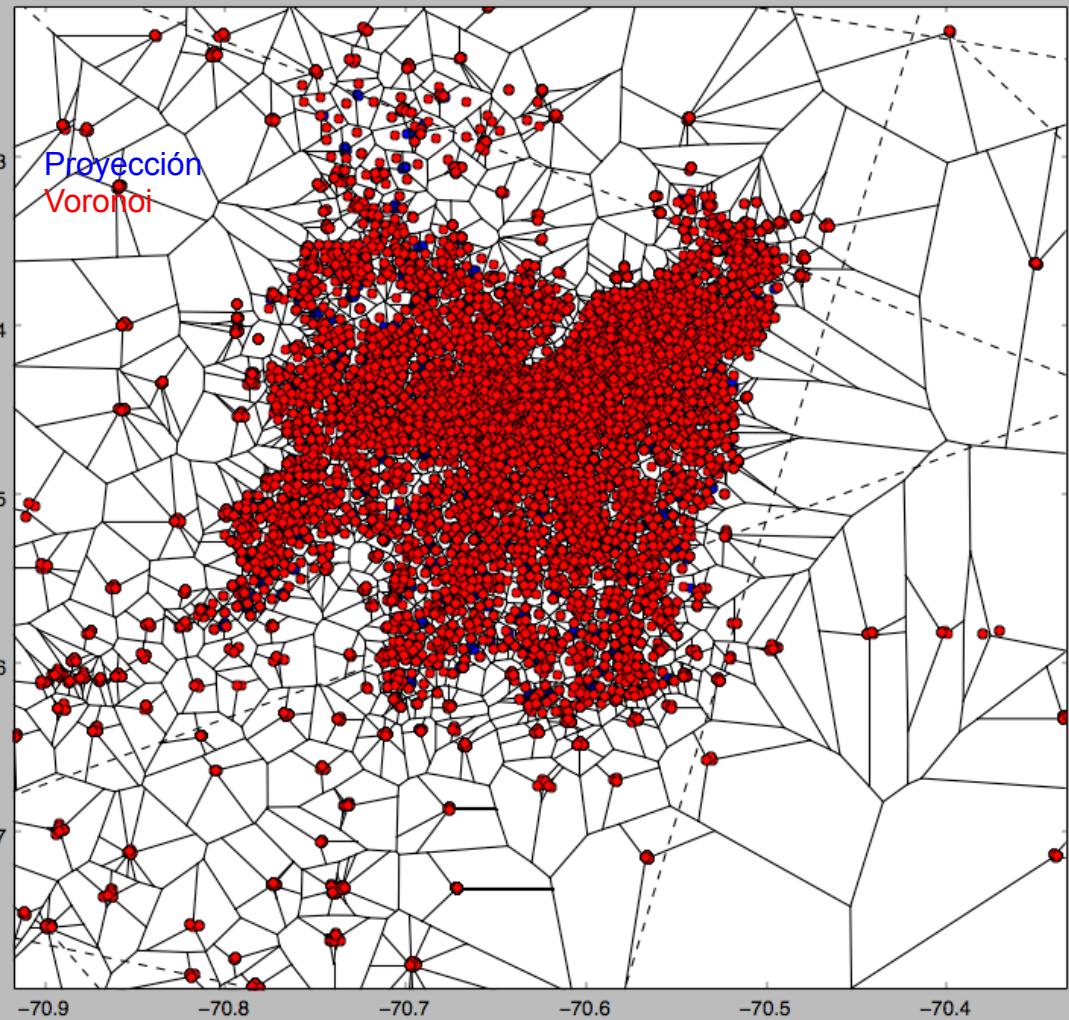
CONTENIDOS

Centro I+D - Chile

- ▶ Estado del arte
- ▶ Trazas de eventos y antenas
- ▶ **Aplicaciones**
- ▶ Desafíos en HPC y Big Data
- ▶ Cooperación: MAMUT

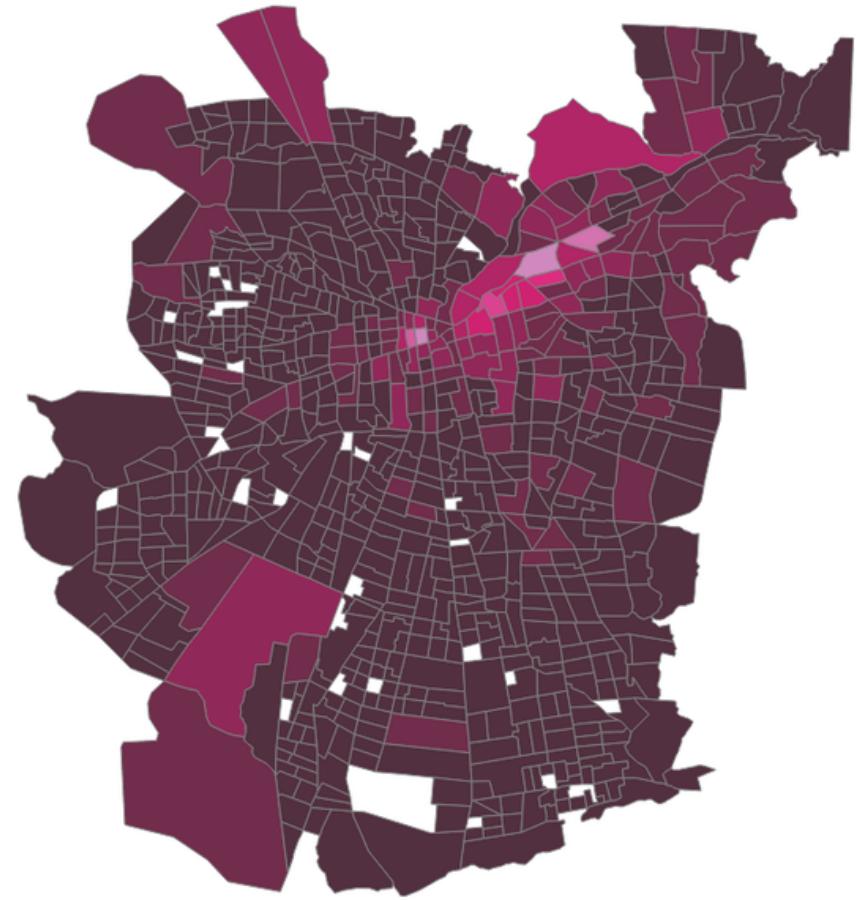
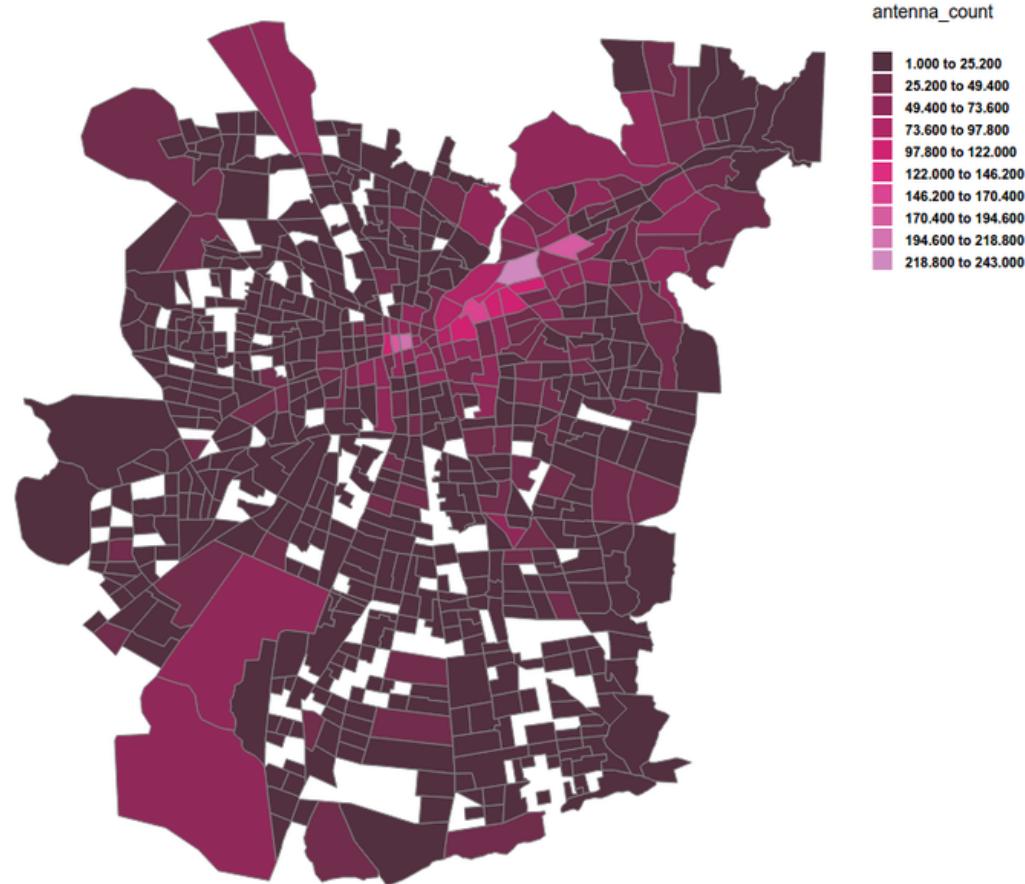
Aplicaciones: modelar cobertura de la red

▶ Diagrama de Voronoi (Santiago)



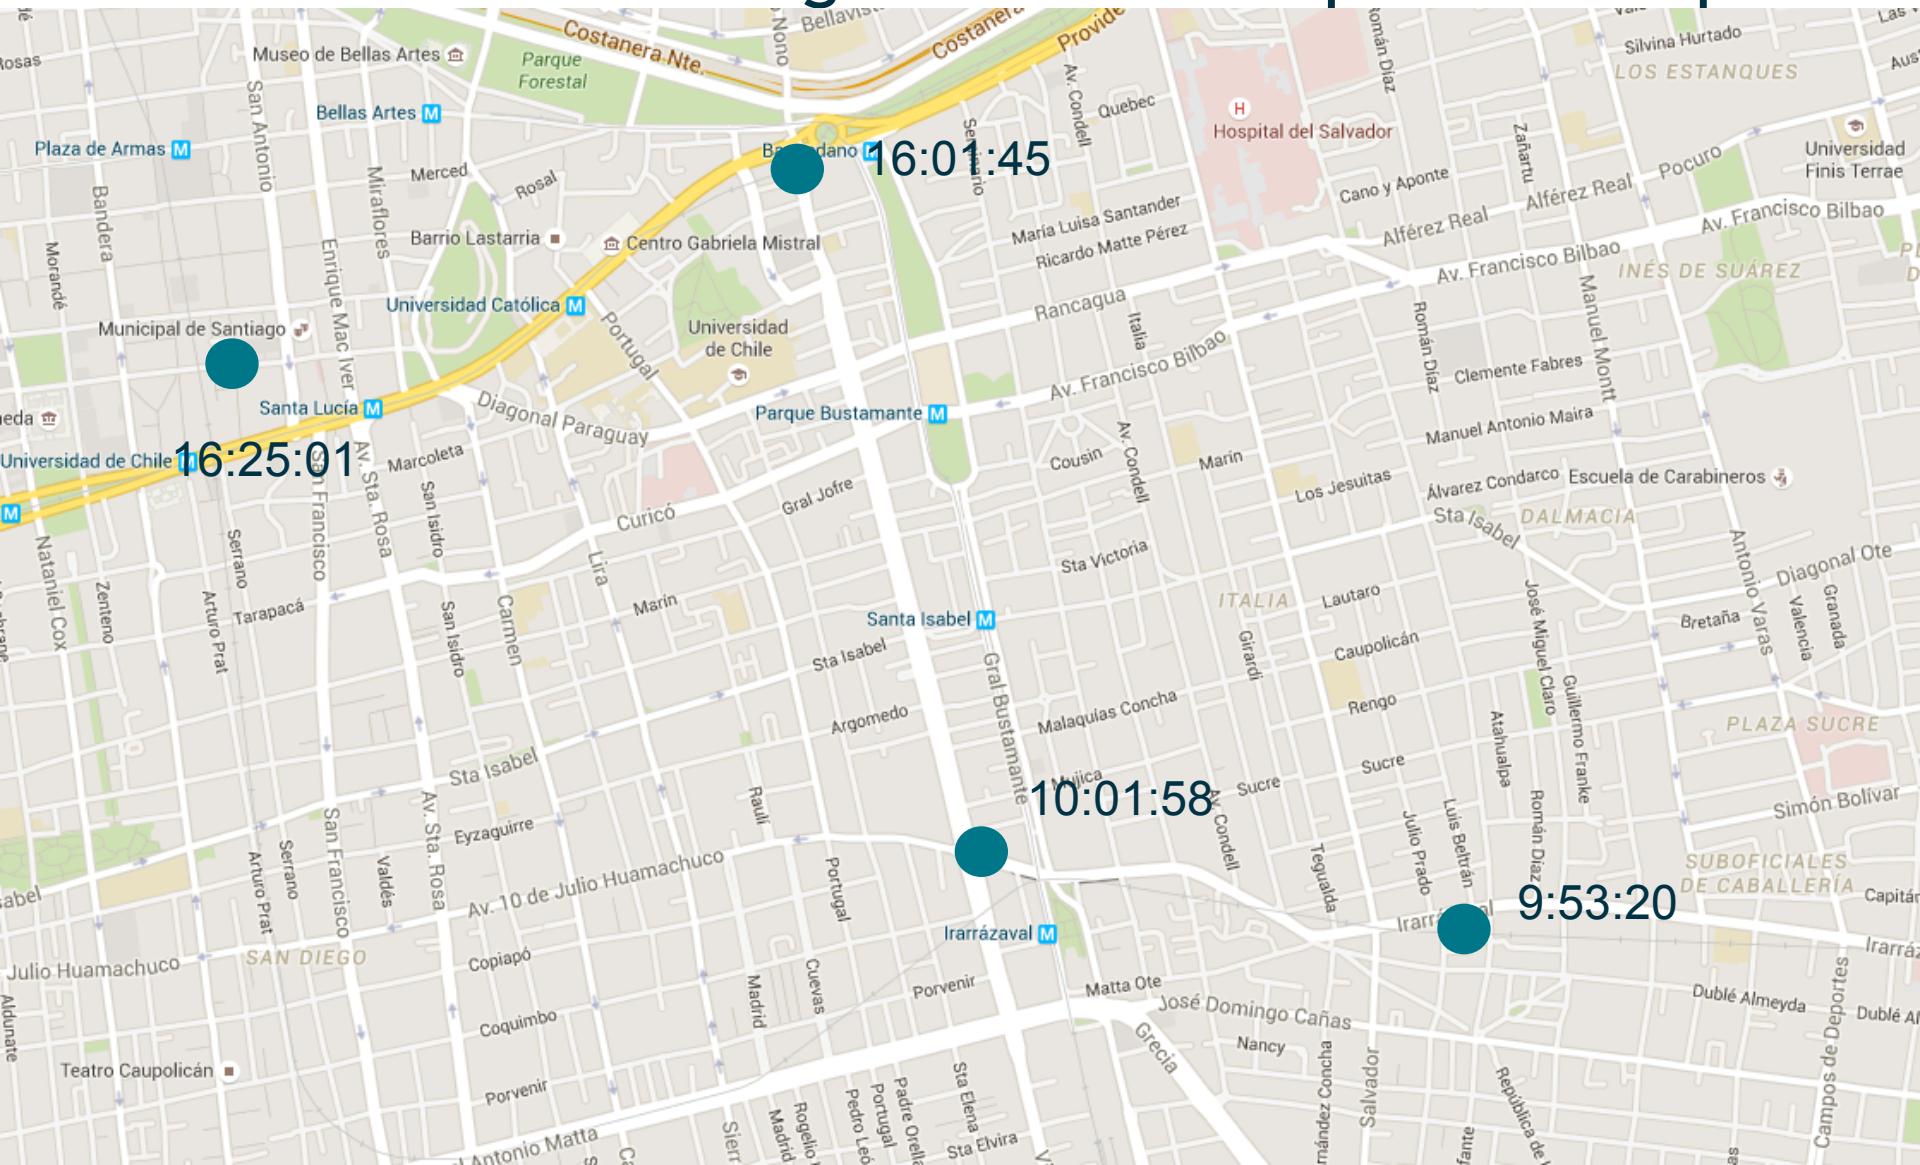
Aplicaciones: modelar cobertura de la red

- ▶ Voronoi para mejorar cobertura por zonificación 777 de Santiago (@carnby)



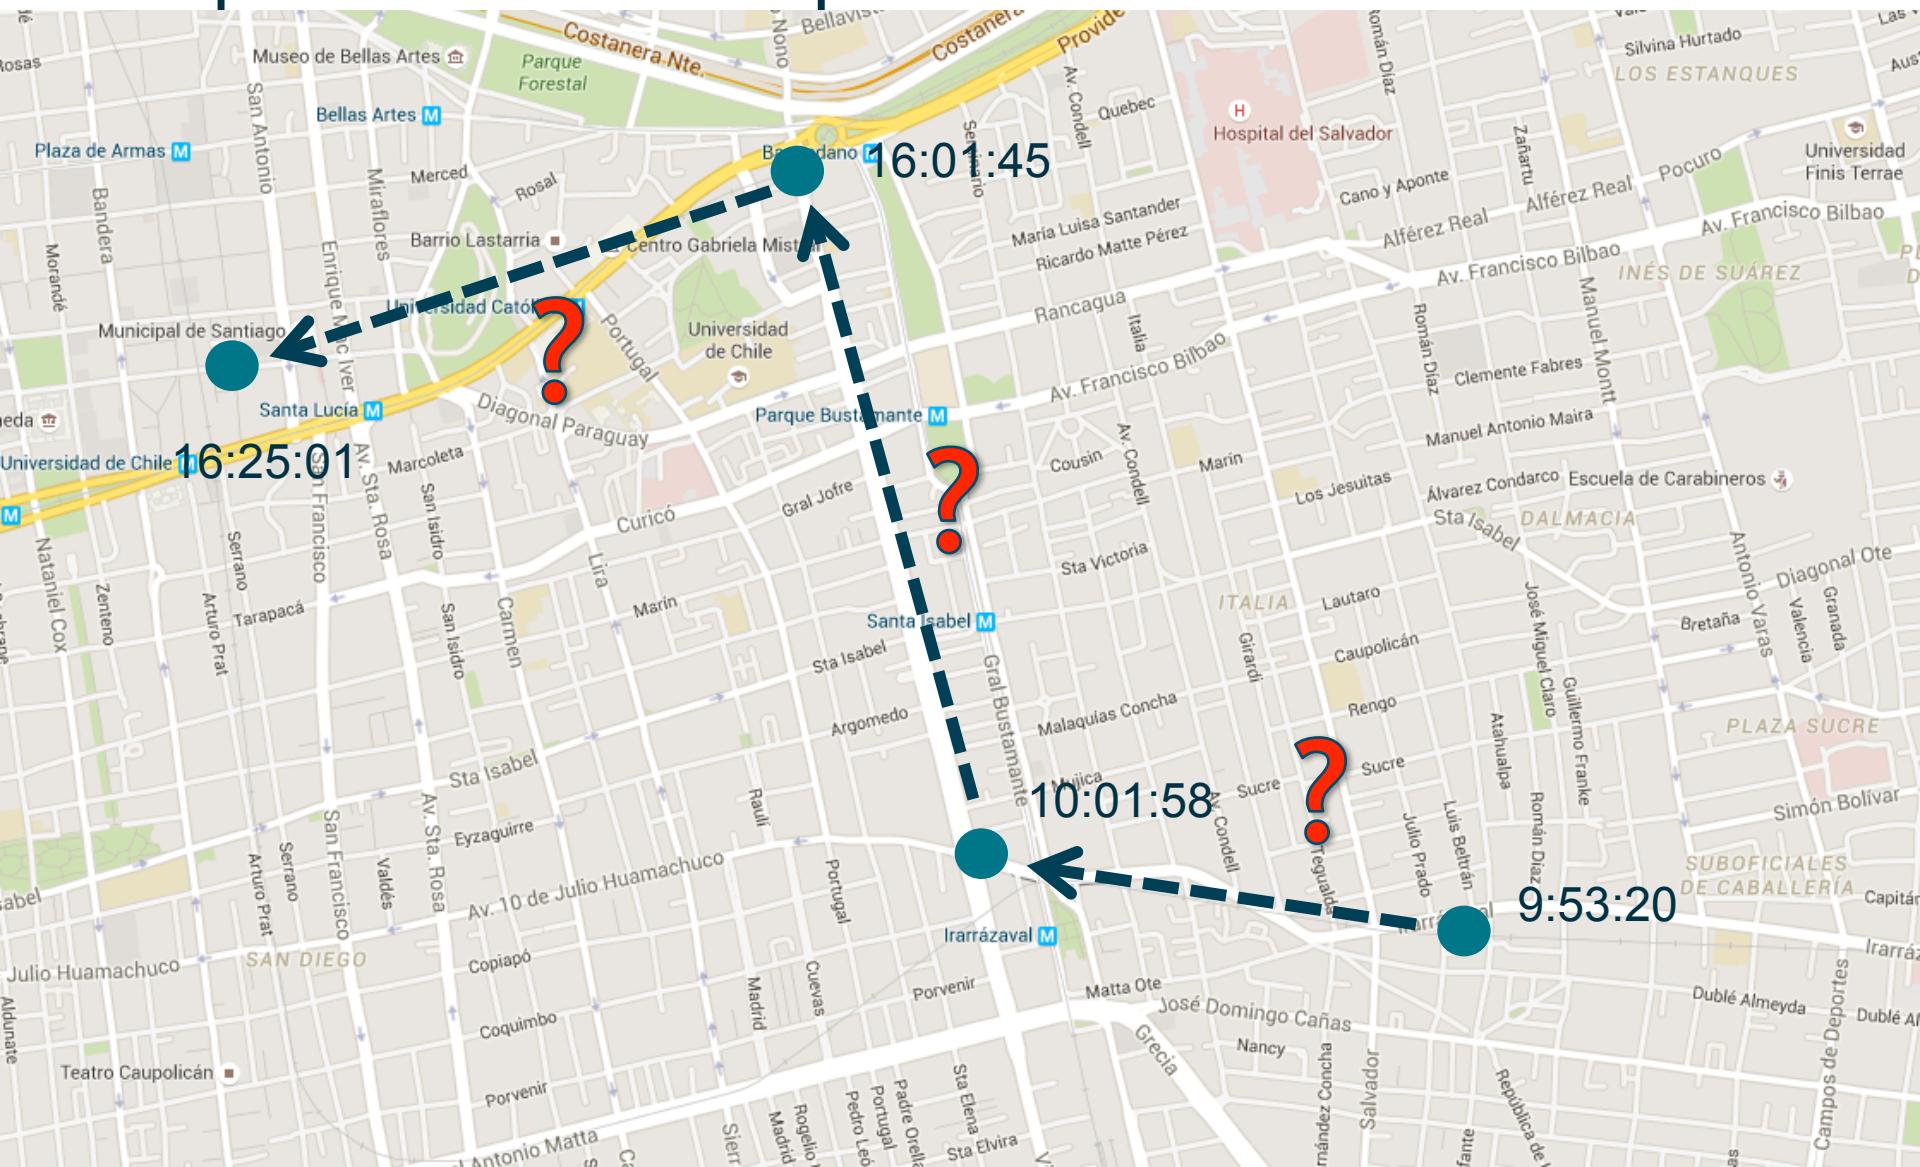
Aplicaciones: interpolación de una traza

Serie de eventos irregulares en el espacio/tiempo



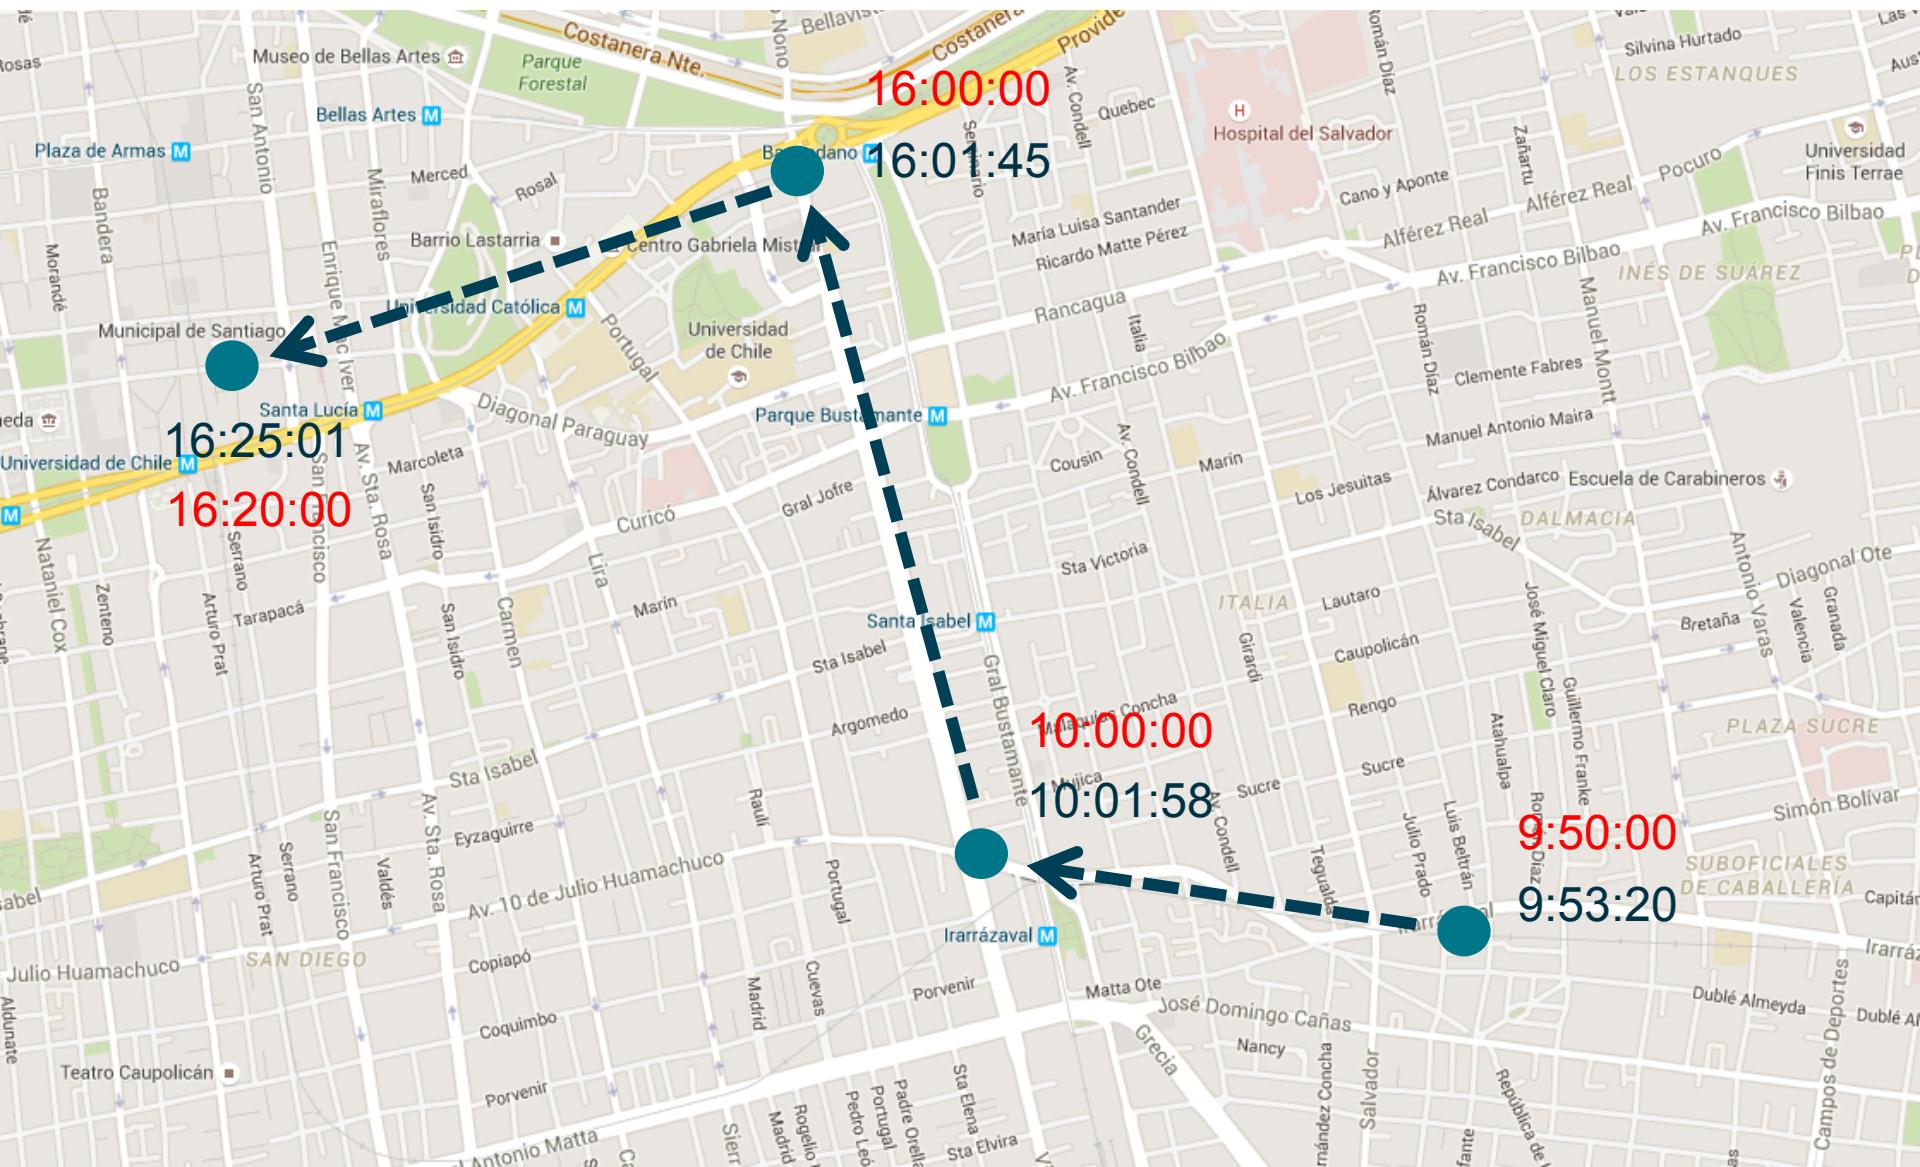
Aplicaciones: interpolación de una traza

Se quiere estimar las posiciones entre cada tramo



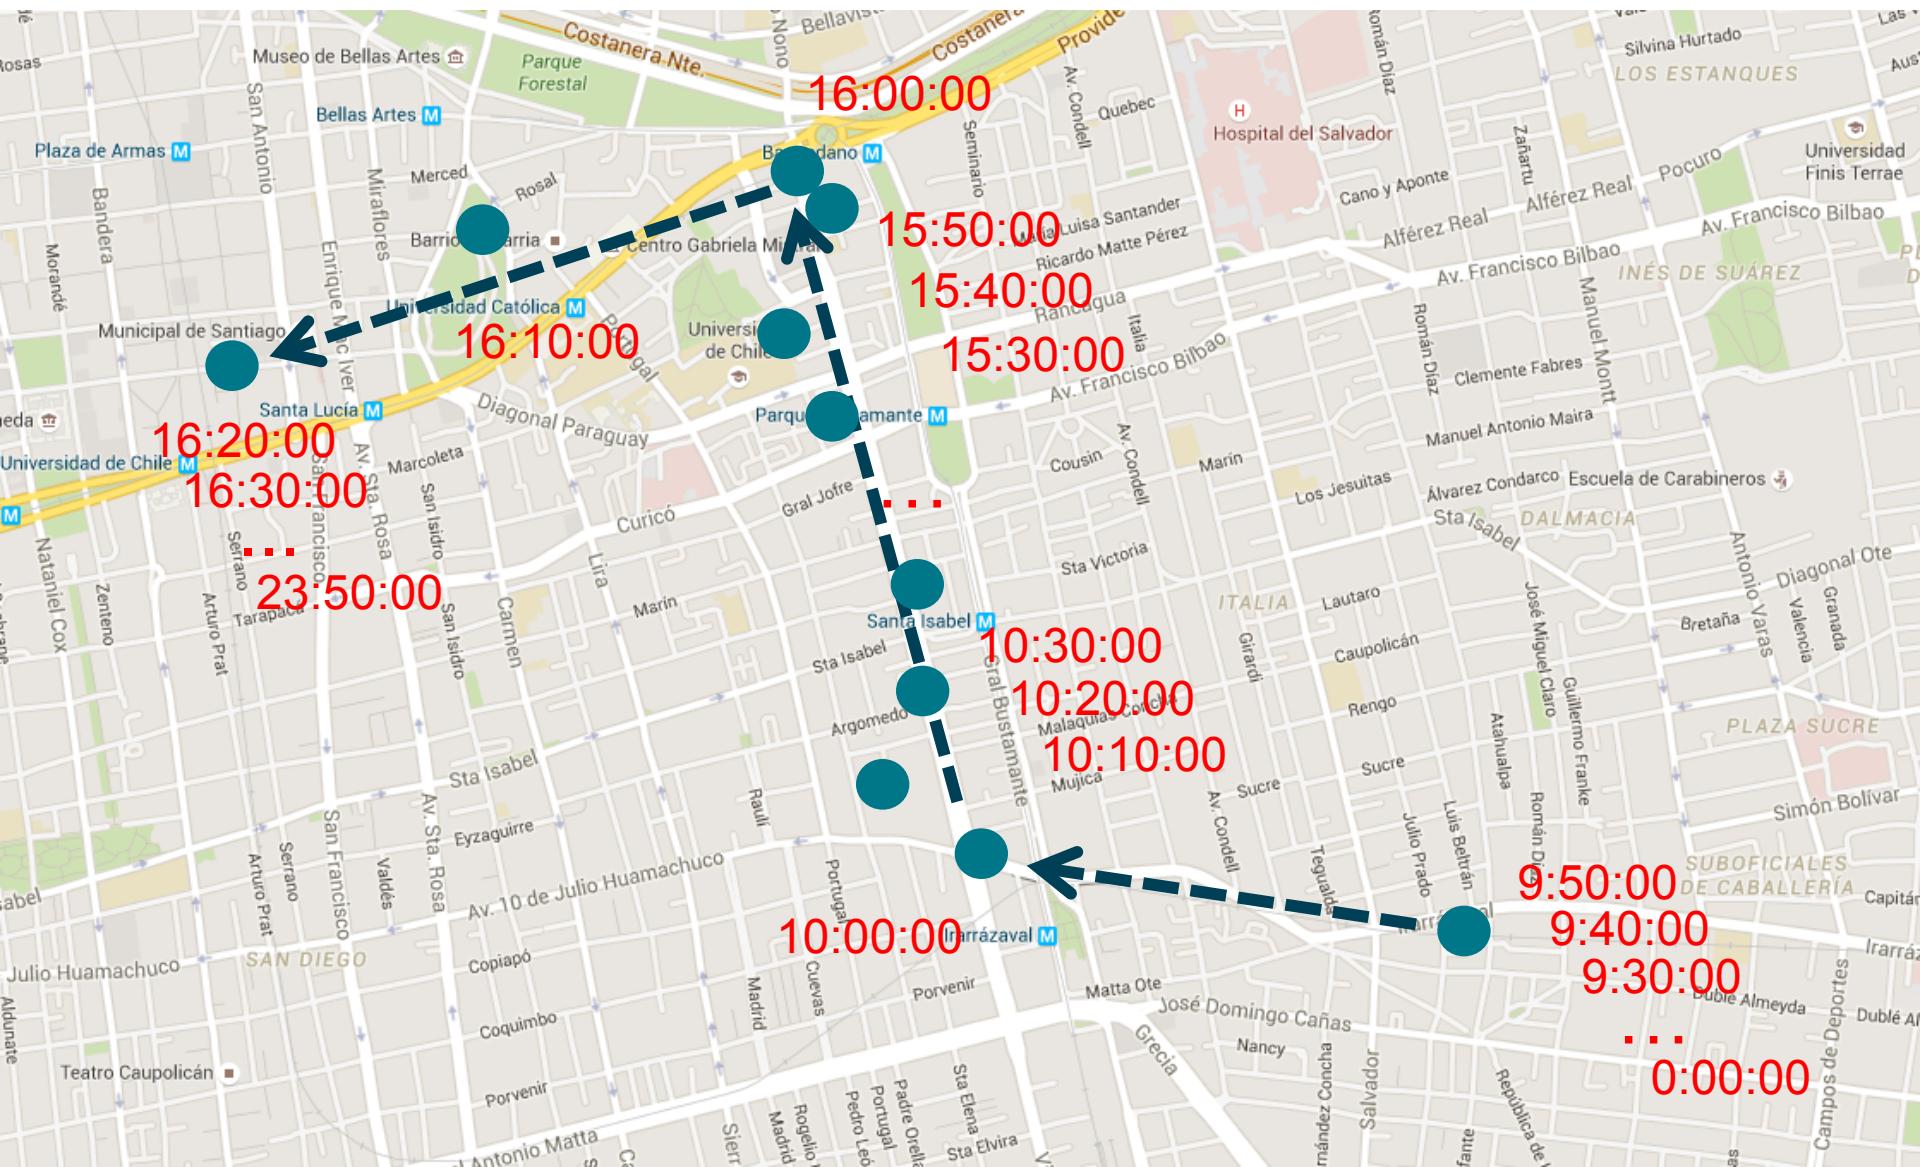
Aplicaciones: interpolación de una traza

Ventanas de 10 minutos:

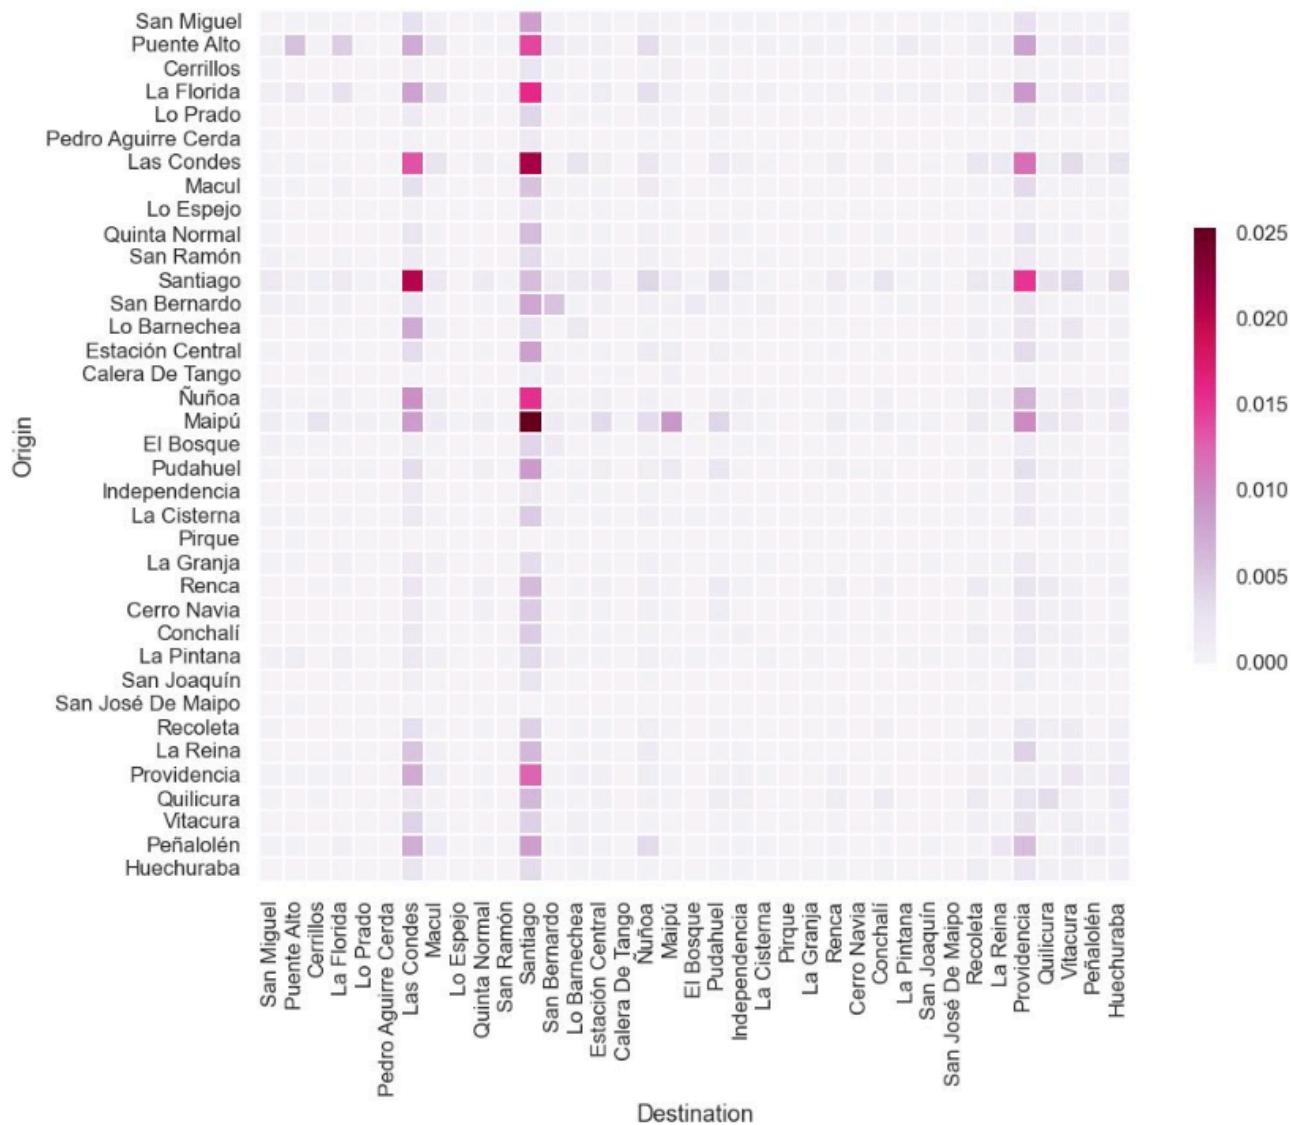


Aplicaciones: interpolación de una traza

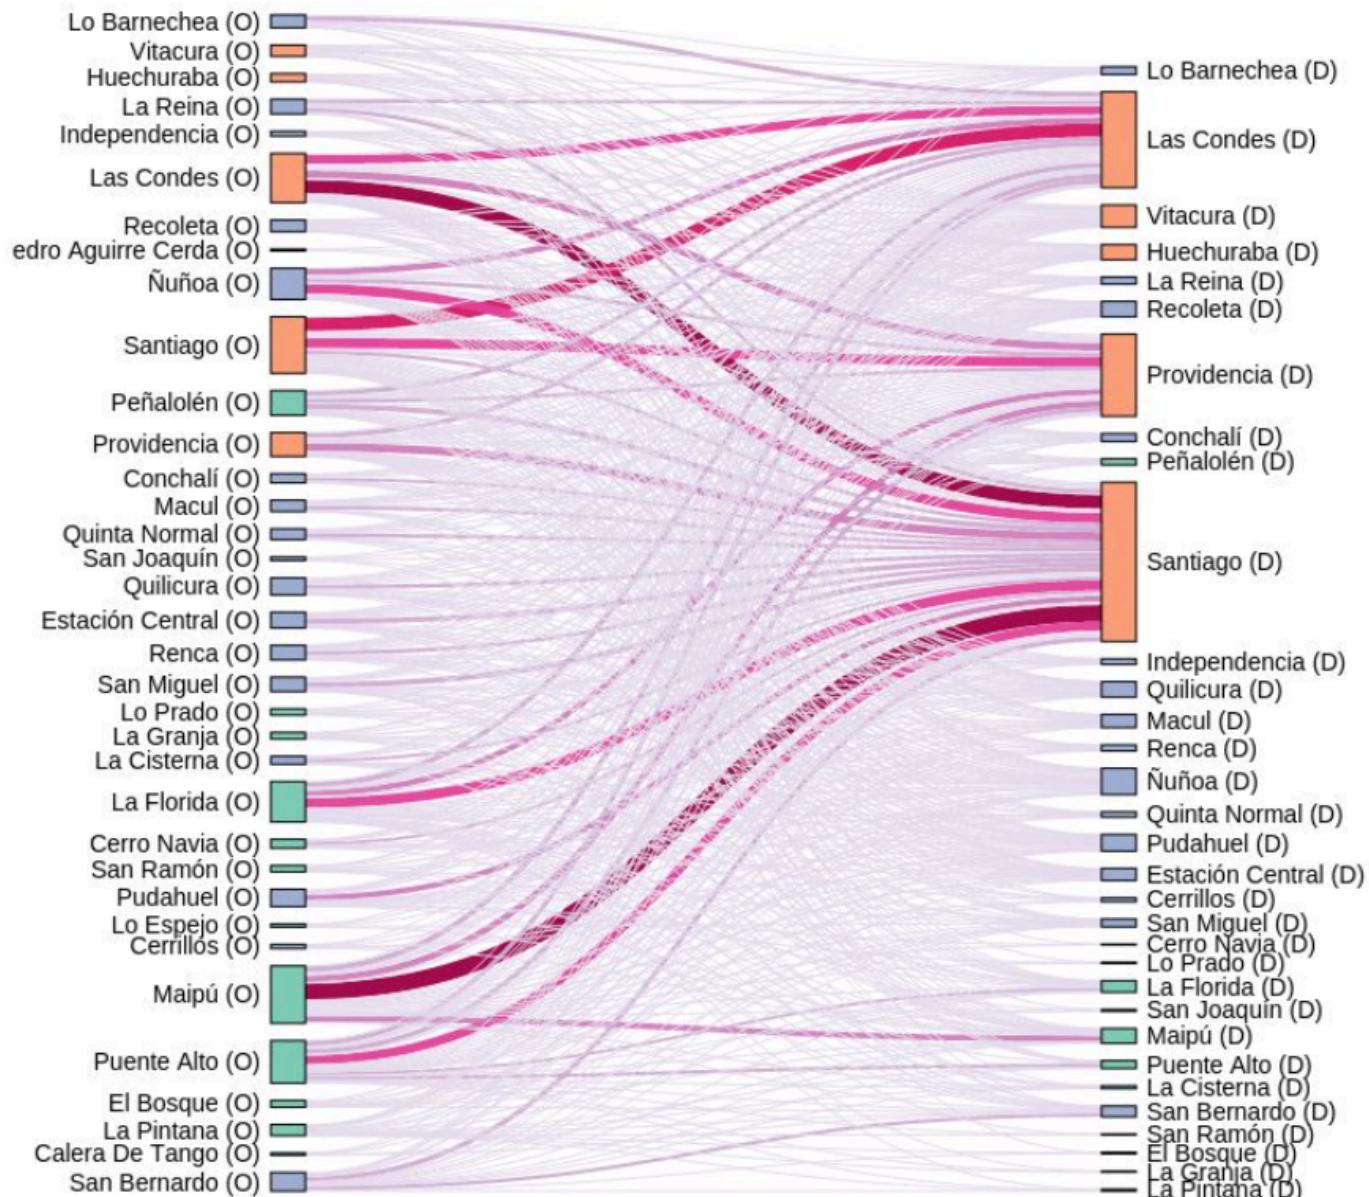
Ventanas de 10 minutos:



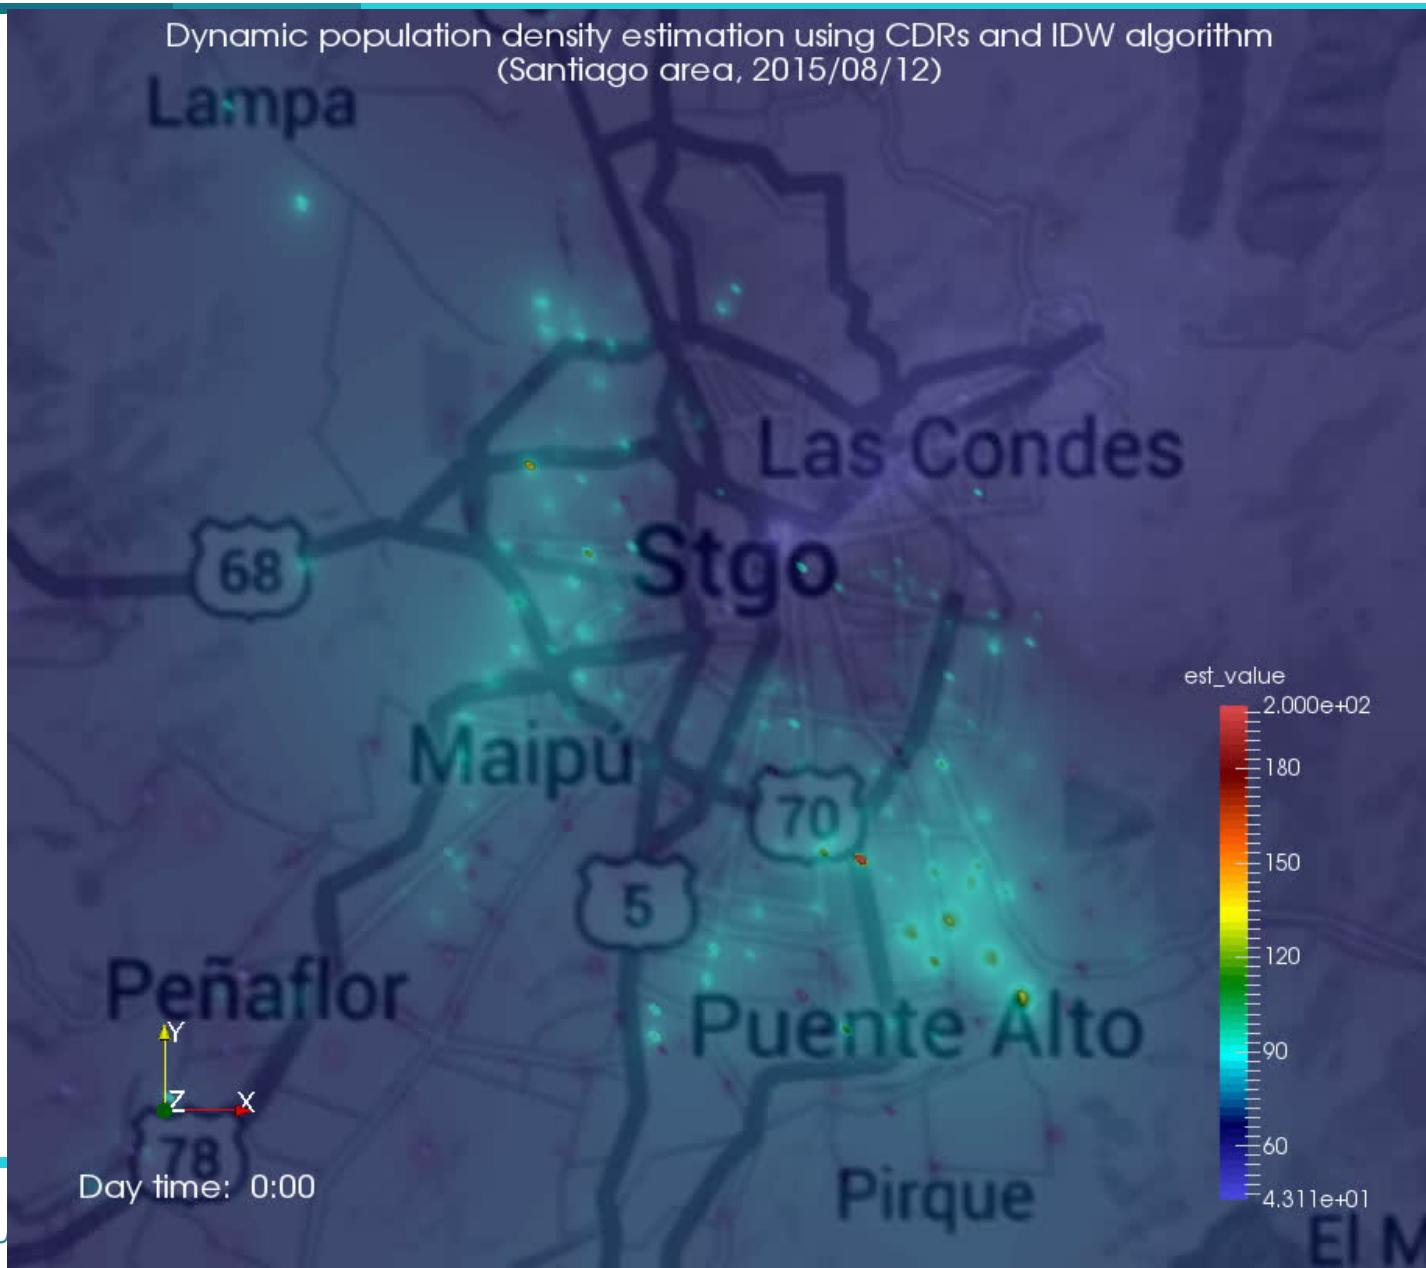
Aplicaciones: estimación matriz OD (@carnby)



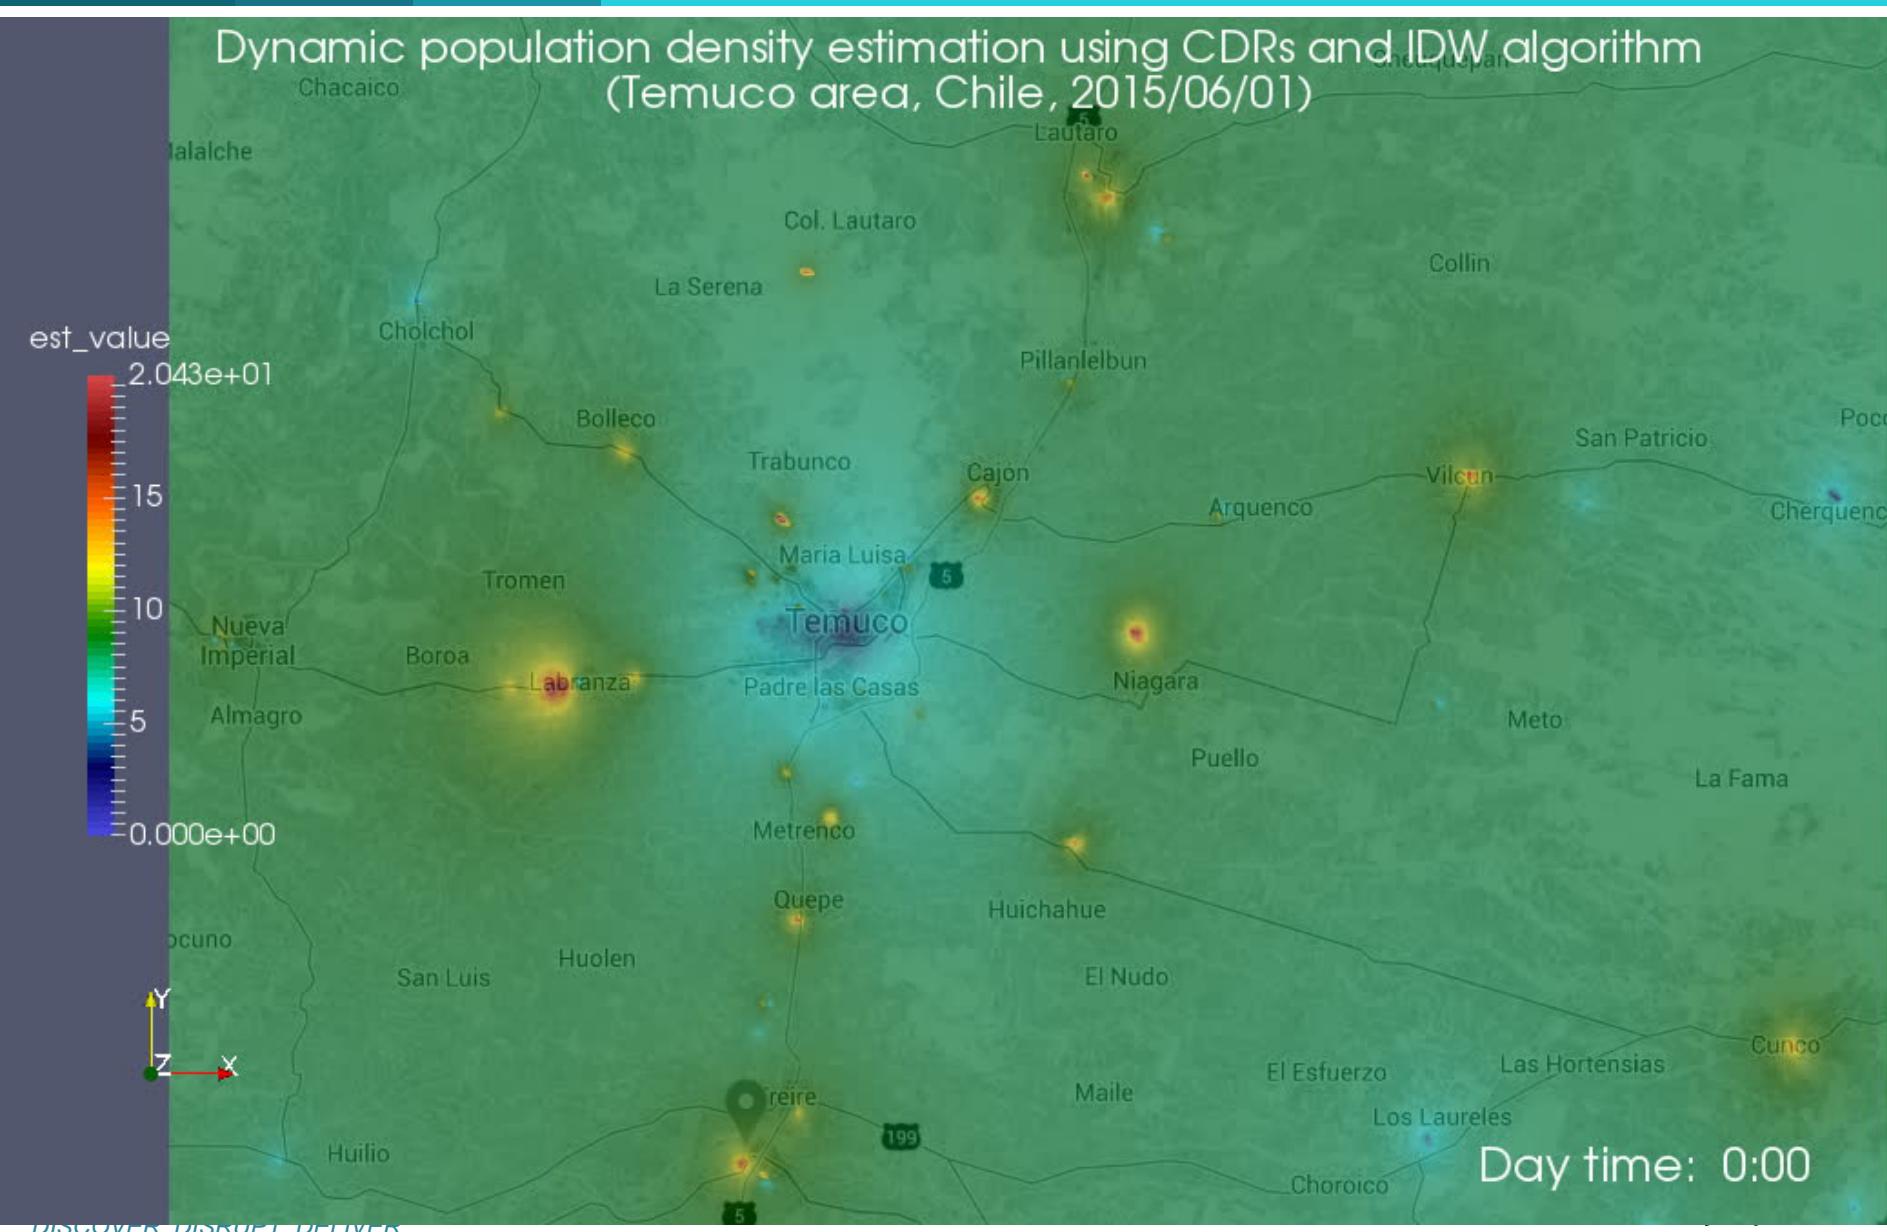
Aplicaciones: estimación matriz OD (@carnby)



Aplicaciones: estimación de dinámica urbana

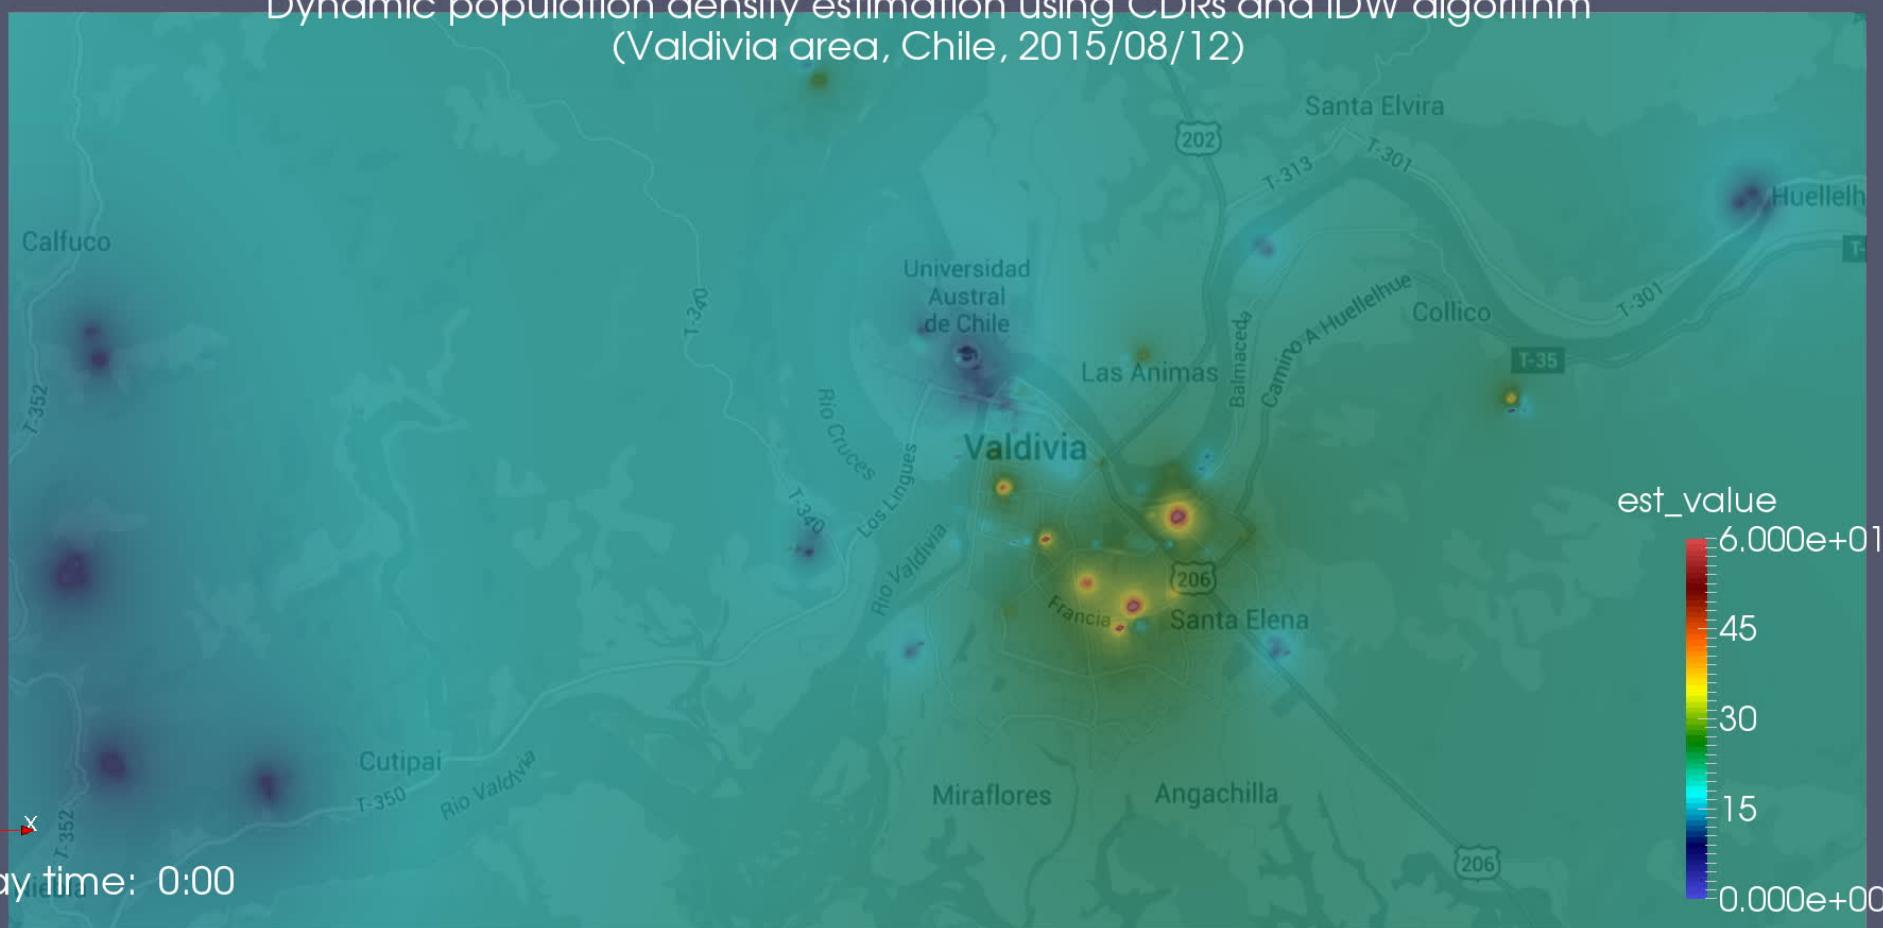


Aplicaciones: estimación de dinámica urbana



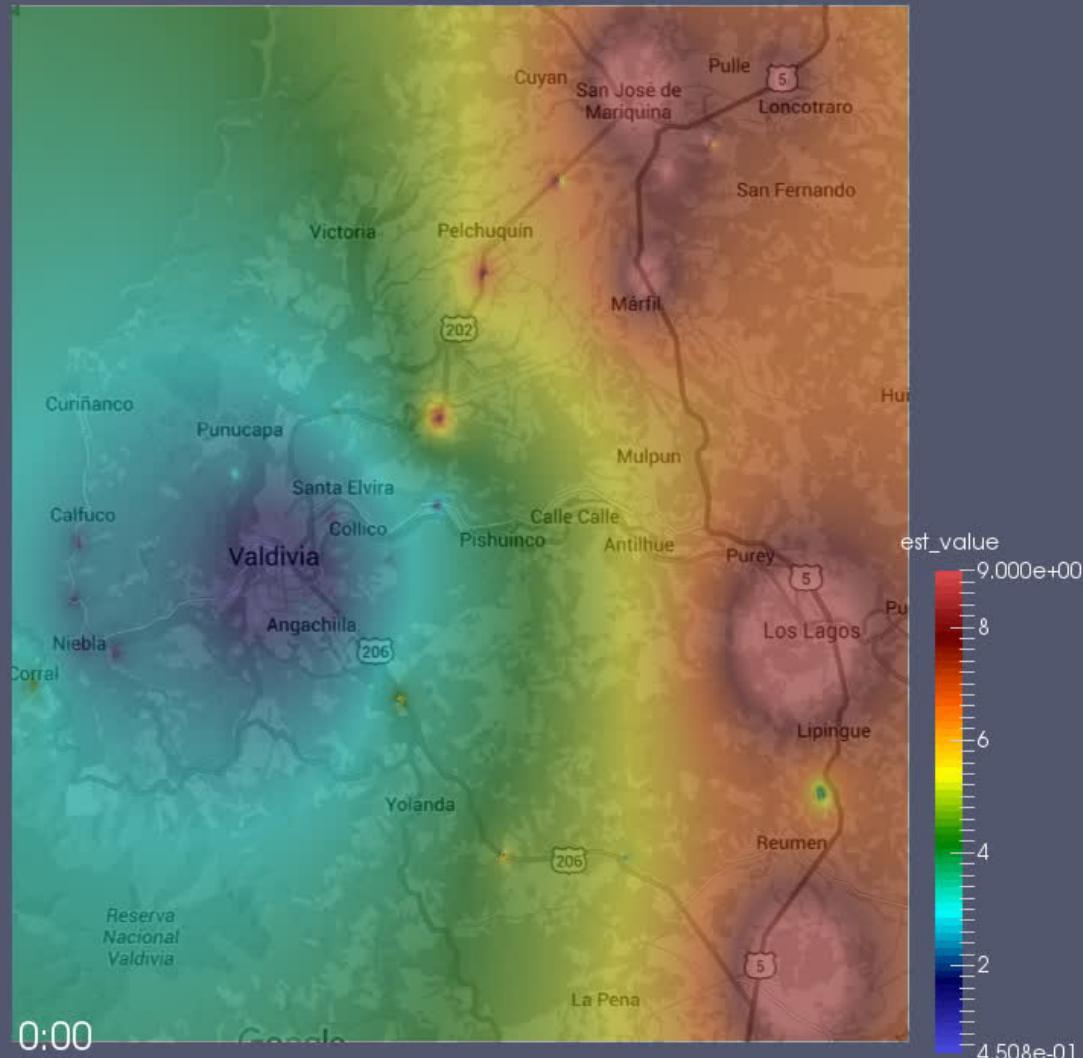
Aplicaciones: estimación de dinámica urbana

Dynamic population density estimation using CDRs and IDW algorithm
(Valdivia area, Chile, 2015/08/12)



Aplicaciones: estimación de dinámica urbana

Dynamic population density estimation using CDRs and IDW algorithm
(Valdivia area, 2015/08/12)



CONTENIDOS

Centro I+D - Chile

- ▶ Estado del arte
- ▶ Trazas de eventos y antenas
- ▶ Aplicaciones
- ▶ Desafíos en HPC y Big Data
- ▶ Cooperación: MAMUT

Desafíos: tiempos de cómputo y consulta

► *¿Cómo optimizar tiempo de cómputo y consulta cuando hay múltiples parámetros de apps/software/hardware?*

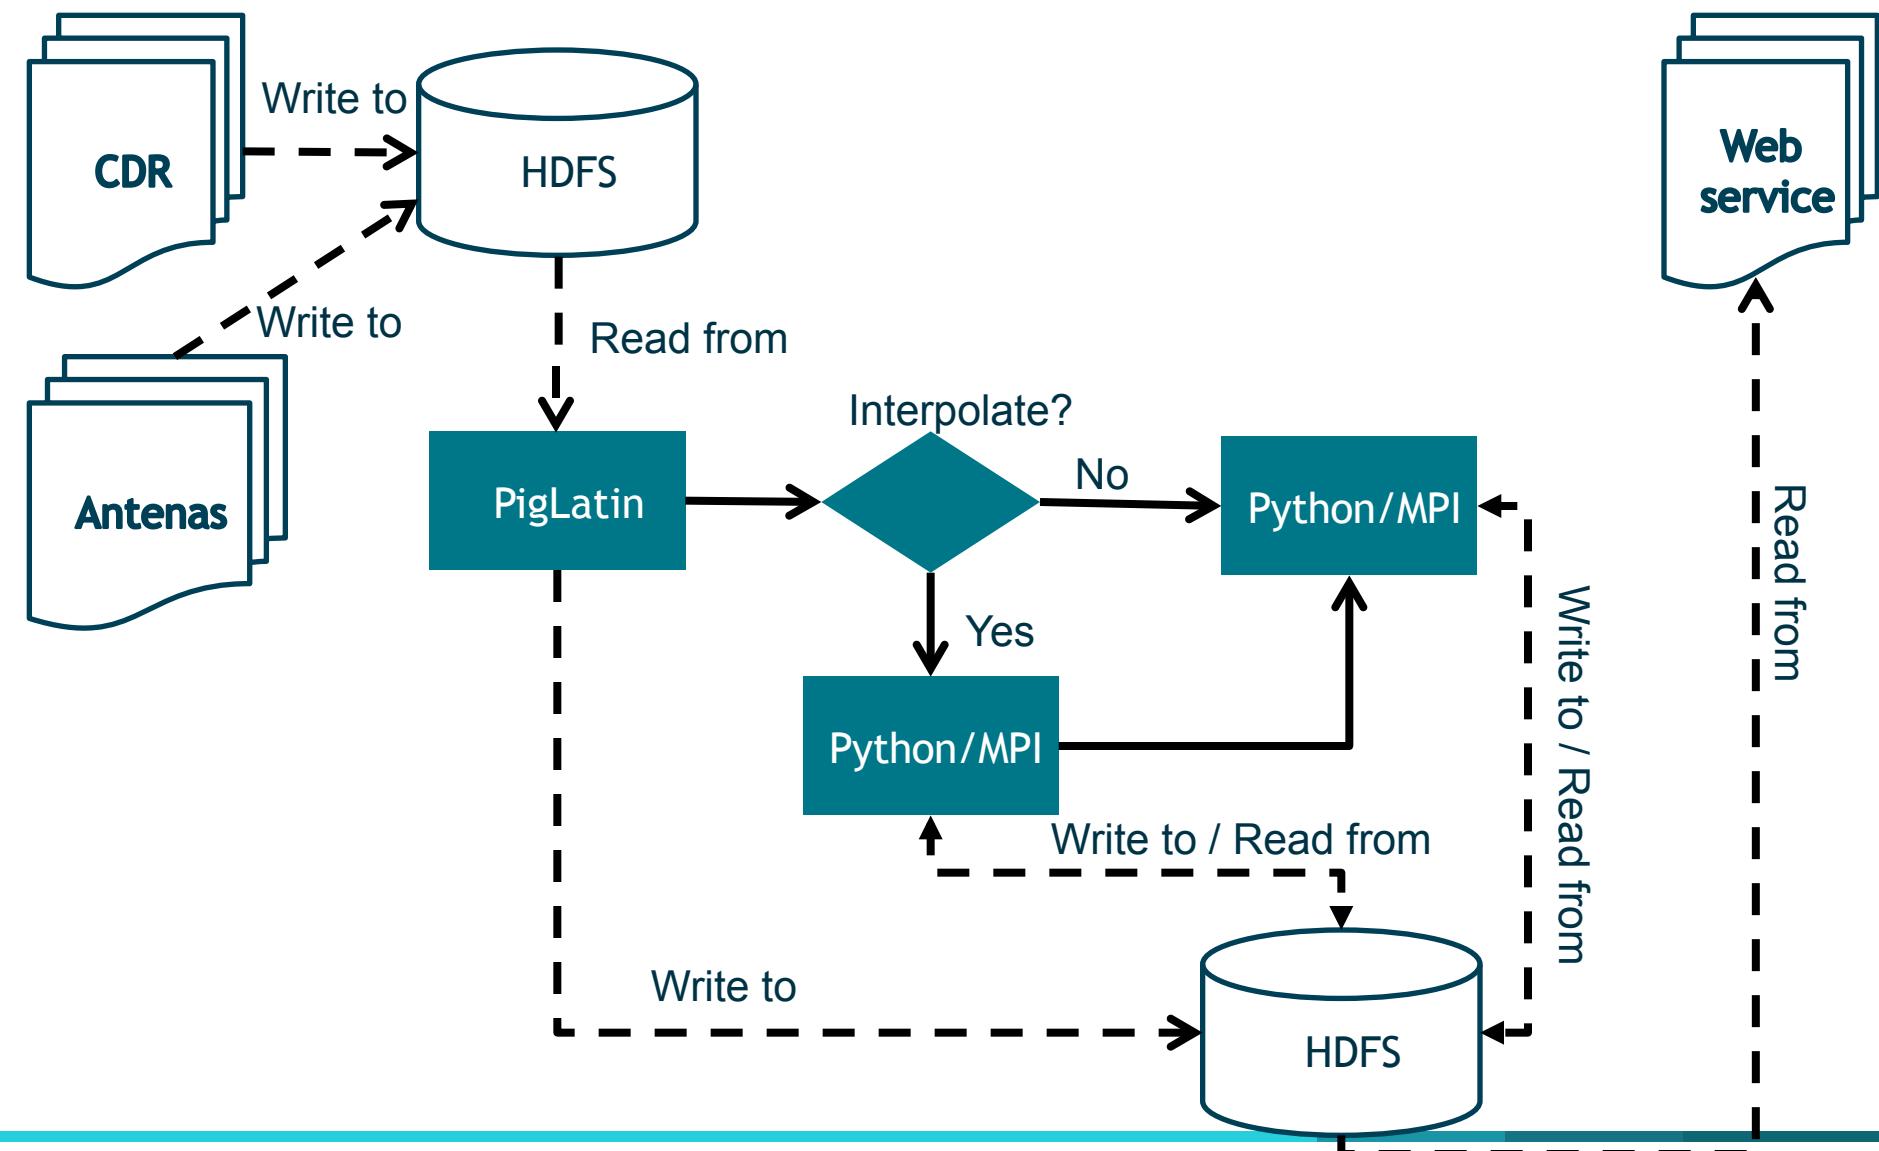
- Optimizar código secuencial antes de parallelizar
- Técnicas de Performance Engineering (extracción/ análisis de trazas de ejecución, profiles y stacks)
- Metodología usando Superficies de Respuesta
- Recordar leyes de Amdhal y Gustafson (cómputo y escalabilidad de datos)
- Modelar efectos de cómputo, memoria y red (identificar proporciones y relaciones)
- Optimización de workflows usando herramientas del ecosistema Hadoop y del stack HPC (MPI y/o CUDA)

Desafíos: ejecución remota

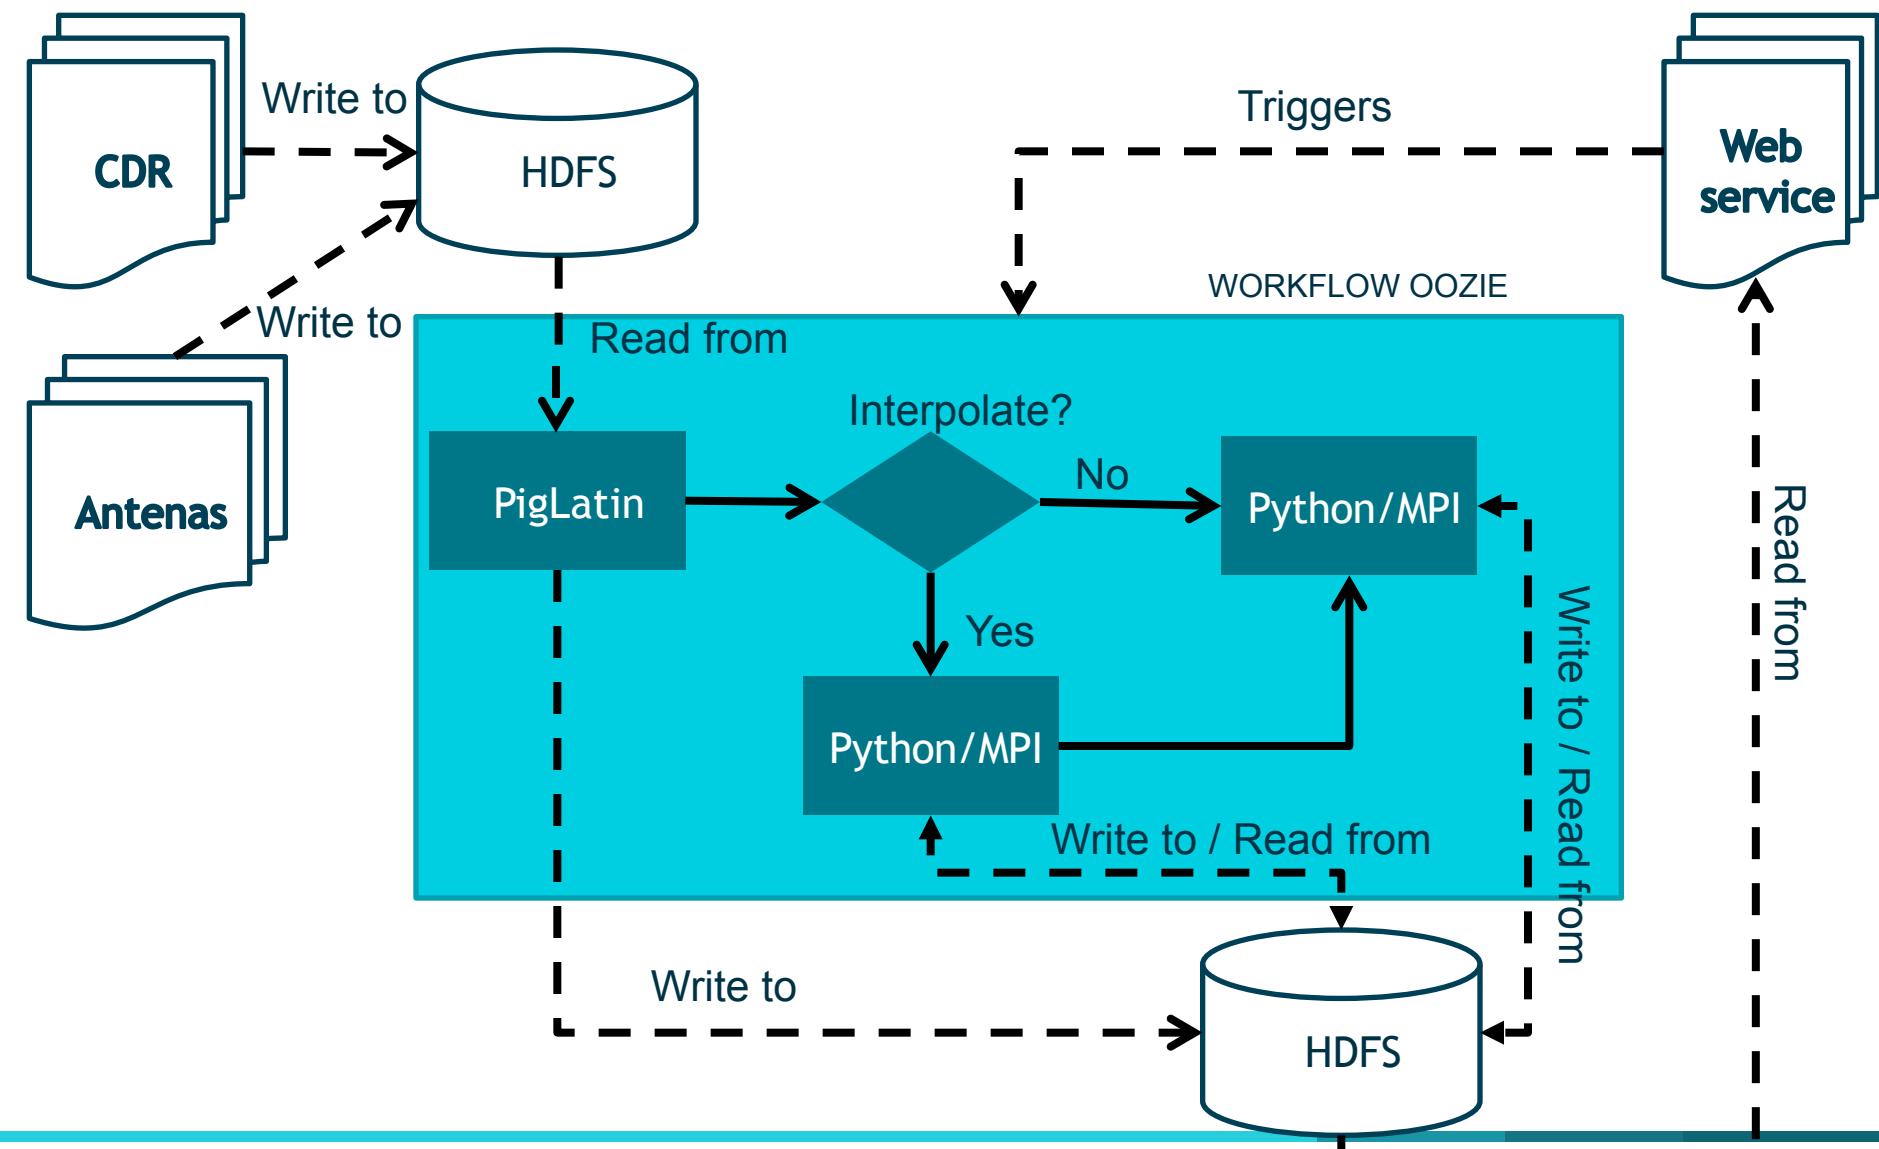
► *¿Cómo ejecutar aplicaciones/workflows usando toda la potencia de cómputo al mínimo costo y a la mayor velocidad?*

- La aplicación debe estar optimizada y paralelizada
- “Ubiquitous HPC” -> usar containers con todas las dependencias (Docker) y habilitar ejecución distribuída
- Evaluar costo/beneficio de clusters dedicados vs on-demand
- Acelerar la creación de máquinas virtuales (estudio de performance de IaaS para cada app/workflow)

Desafíos: ejecución remota

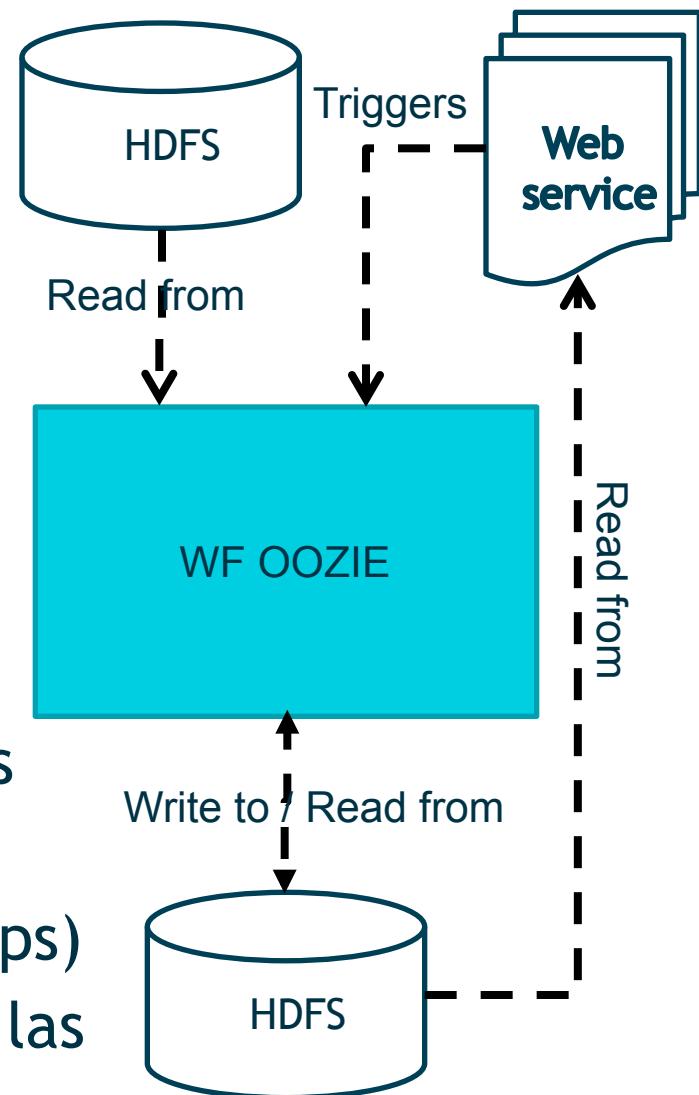


Desafíos: ejecución remota



Desafíos: ejecución remota

- ▶ ¿Qué ocurre al ejecutar el WF?
 - Levantar cluster Hadoop, sólo si fue eliminado previamente
 - Descargar containers en todos los nodos, sólo si las deps no están instaladas en el cluster
 - Chequear errores de instalación y ejecución antes de lanzar el WF
 - Chequear disponibilidad de los HDFSs
 - Tolerancia a fallos de MPI
 - Tolerancia a fallos de GPUs (otras apps)
 - Mantener escalabilidad (depende de las apps en el WF)



Desafíos: avalancha de datos

- ▶ Cantidad de información en nuestros sistemas se incrementa día a día
 - CDR
 - Telemetría (>>CDR)
 - Tarjeta BIP!
 - Redes sociales
 - Variables ambientales
 - IoT (cámaras, sensores, medidores,...)
 - Otros...

Desafíos: avalancha de datos

► *¿Cómo organizar y almacenar la avalancha de datos que llegarán?*

- Capturar datos desde la fuente (ej. servidor ftp montado en datacenter de Telefónica, enviando datos a nuestros sistemas)
- Filesystem distribuído basado en HDFS (interacción con ecosistema Hadoop)
- Procesamiento en tiempo real (ej. workflows que usen apps Apache Spark, topologías de Apache Storm)

Desafíos: seguridad y anonimización

► *¿Cómo anonimizar los datos de forma segura pero permitiendo identificar patrones de comportamiento en largos períodos de tiempo?*

- Única salt -> IDs anonimizados únicos por usuario, a cambio de baja seguridad del sistema
- Salt dinámica -> diferentes IDs anonimizados para cada usuario, pero con una alta seguridad del sistema
- Usar mucha capacidad de cómputo para realizar una anonimización segura en tiempo real.

CONTENIDOS

Centro I+D - Chile

- ▶ Estado del arte
- ▶ Trazas de eventos y antenas
- ▶ Aplicaciones
- ▶ Desafíos en HPC y Big Data
- ▶ Cooperación: MAMUT

Cooperación

► MAMUT

- Plataforma que entrega a investigadores un cluster y acceso a datos cargados en un storage WASB.
- Permite realizar consultas sobre los datos usando herramientas Hadoop (ej. MapReduce, Pig, Hive, ...)
- Opcionalmente permite distribuir cómputo usando diversos modelos de programación (ej. MPI)
- Ejemplo de uso:
 - Cluster de 6 nodos con 4 cores c/u (2 head, 4 workers)
 - Herramientas Hadoop instaladas
 - OpenMPI instalado
 - 10 días de CDRs de voz y datos cargados
 - Acceso SSH

Cooperación: MAMUT

MAMUT

Cluster

Jobs

Datasets

Subscriptions

Main Panel

Carlos Guerrero ▾

Cluster

You have no running cluster yet

User name

Password

Confirm

Working Nodes ▼

A4 (8 Cores, 14GB RAM, 16 Disks)

A6 (4 Cores, 28GB RAM, 8 Disks)

A7 (8 Cores, 56GB RAM, 16 Disks)

A10 (8 Cores, 56GB RAM, 16 Disks)

A11 (16 Cores, 112GB RAM, 16 Disks)

D3 (4 Cores, 14GB RAM, 8 Disks, 200GB Local SSD)

D4 (8 Cores, 28GB RAM, 16 Disks, 400GB Local SSD)

D12 (4 Cores, 28GB RAM, 8 Disks, 200GB Local SSD)

D13 (8 Cores, 56GB RAM, 16 Disks, 400GB Local SSD)

D14 (16 Cores, 112GB RAM, 32 Disks, 800GB Local SSD)

Head Node Size ▼

Worker Nodes Size ▼

Max Inactivity ▼

Cooperación: MAMUT

MAMUT Cluster Jobs Datasets Subscriptions Main Panel Carlos Guerrero ▾

Cluster

tidchile-research

Running

The cluster **tidchile-research** was created 14 days ago.

SSH	tidchile-research-ssh.azurehdinsight.net
HTTPS	tidchile-research.azurehdinsight.net
headnode	2 x Standard_D3
workernode	1 x Large
zookeepermode	3 x Small
Cores Used	12

[DELETE](#)

Cooperación: MAMUT

MAMUT Cluster Jobs Datasets Subscriptions Main Panel Carlos Guerrero ▾

Container

tidchile Created

The container **tidchile** was created 3 months ago.

Endpoint	https://tidchile.blob.core.windows.net/
Endpoint	https://tidchile.queue.core.windows.net/
Endpoint	https://tidchile.table.core.windows.net/
Endpoint	https://tidchile.file.core.windows.net/
Location (Primary)	East US
Location (Secondary)	West US

DELETE

Cooperación: MAMUT

MAMUT

Cluster

Jobs

Datasets

Subscriptions

Main Panel

Carlos Guerrero ▾

Datasets

Filter by prefix (Click on the folder icon to expand)

✉ mamut

✉ movistar

✉ cdr

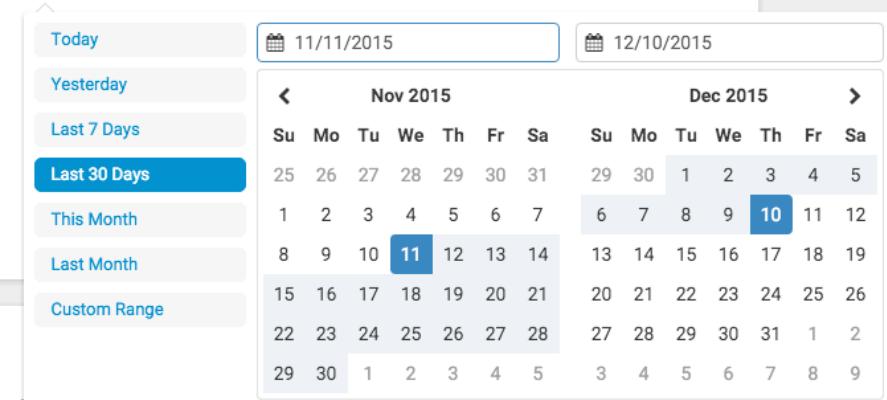
data sms mms voice

✉ dmc

✉ cell

Filter by date

11/11/2015 ▾ 12/10/2015 ▾



Name

Master Container A.....

mamut/movistar/cdr/data/2015/11/11/

Available

Copy

mamut/movistar/cdr/data/2015/11/12/

Available

Copy

mamut/movistar/cdr/data/2015/11/13/

Available

Copy

mamut/movistar/cdr/data/2015/11/14/

Available

Copy

mamut/movistar/cdr/data/2015/11/15/

Available

Copy

mamut/movistar/cdr/data/2015/11/16/

mamut/movistar/cdr/data/2015/11/17/

mamut/movistar/cdr/data/2015/11/18/

mamut/movistar/cdr/data/2015/11/19/

Cooperación: MAMUT

MAMUT

Cluster

Jobs

Datasets

Subscriptions

Main Panel

Carlos Guerrero ▾

Subscriptions

Add new subscription

Subscription name	Subscription id
Microsoft Azure Enterprise	19d81882-cd38-4a21-a41e-f87c09861195
TIDChile-mamut-dev	7352f365-fdd0-48b6-9b93-6f3b04a6e76a

Users

Add new user

Name	Email	Subscription
		Microsoft Azure Enterprise
		Microsoft Azure Enterprise
		Microsoft Azure Enterprise

Cooperación: MAMUT

MAMUT

Cluster

Jobs

Datasets

Subscriptions

Main Panel

Carlos Guerrero ▾

Jobs

ID	Job Name	Duration	MapReduce Progress	Map	Reduce	Priority	State
job_1449080548701_0001	demo count cdr	an hour	<div style="width: 85%;"><div style="width: 100%;"> </div></div>	85 %	28 %	NORMAL	RUNNING

Cooperación: MAMUT

- ▶ Primeros usuarios:
 - Centro Inteligencia de Negocios, U. de Chile
 - Ingeniería de Transporte, U. de Chile
 - Instituto de Data Science, U. del Desarrollo
 - U. Austral
- ▶ ¿Cómo ser usuario?
 - Plantear plan de trabajo y firmar NDAs
 - Aprobación por parte del directorio

Cooperación: pasantías de investigación

- ▶ Se buscan profesionales/egresados para desarrollar investigaciones en:
 - HPC (Profiling, Tracing, ejecución remota)
 - Big Data (MapReduce, Tez, Hadoop, Spark)
 - Machine Learning (imágenes, clustering, deep learning)
 - Modelamiento estocástico (simulación estocástica espacio-temporal)
- ▶ Contacto: oscar.peredoa@telefonica.com

¡Gracias!

Desafíos: tiempos de cómputo y consulta

- ▶ Diversas aplicaciones
 - Machine Learning
 - Geostatistics / Spatial statistics / Time series analysis
 - Linear algebra
 - Optimization (heuristics, gradient-based)
 - Graph computations
 - 2D/3D visualization
- ▶ Diversas tecnologías de software:
 - Java MapReduce
 - SQL-style Pig/Hive (ejecutando java MR en bajo nivel)
 - Scala/Python Spark
 - Python, R, Perl con múltiples módulos/packages
 - MPI, OpenMP, Python Multiprocess, CUDA, ...
 - Docker, ELK, Orion/FIWARE,...
- ▶ Diversas arquitecturas de hardware:
 - Servidores web
 - Clusters usando máquinas virtuales y containers
 - Clusters en bare-metal
 - GPUs o MICs

Estado del arte

► Uso de CDRs para movilidad urbana:

- Exploring Regression for Mining User Moving Patterns in a Mobile Computing System (Hung 2005)
- Reality mining: sensing complex social systems (Eagle, 2006)
- Understanding individual human mobility patterns (González, 2008)
- The dynamics of a mobile phone network (Hidalgo, 2008)
- Limits of Predictability in Human Mobility (Song, 2010)
- HCMM: Modelling spatial and temporal properties of human mobility driven by users' social relationships (Boldrini, 2010)
- Human Mobility Prediction based on Individual and Collective Geographical Preferences (Calabrese, 2010)
- Human Mobility Modeling at Metropolitan Scales (Isaacman, 2012)
- Study on Urban Mobility and Dynamic Population Estimation by Using Aggregate Mobile Phone Sources (Horanont, 2012)
- Exploration and Analysis of Massive Mobile Phone Data: A Layered Visual Analytics approach (van den Elzen, 2013)
- Probabilistic Inference of Unknown Locations : Exploiting Collective Behavior when Individual Data is Scarce (Blumenstock, 2014)
- Origin-destination trips by purpose and time of day inferred from mobile phone data (Alexander, 2015)
- Analyzing Cell Phone Location Data for Urban Travel: Current 3 Methods, Limitations and Opportunities (Colak, 2015)

Desafíos en HPC y Big Data

	HPC	Big Data
Since	1960's (Cray & CDC)	2000's (Yahoo, Google, Apache)
Drivers	Science & Engineering	Bussiness & Databases
Scope of apps	Memory and CPU-bounded	Memory & I/O-bounded
Main laguages	C/C++, Fortran	Java, Python
Main tools	MPI, OpenMP, CUDA	Hadoop, MapReduce
Focus	Performance	Fault-tolerance

Desafíos: tiempos de cómputo y consulta

OD matrix estimation

Pig+Tez (Hadoop)	Time [seconds]	Speedup
Baseline (several scripts, manual exec)	~1200	1.00x
Bash execution	730	1.64x
Merge in 1 script	234	5.12x
Optimal number of mappers and reducers	150	8.00x
Optimal heap size	140	8.57x
Java UDF	130	9.23x
Compression LZO	?	?

Trace interpolation

Python+MPI	Time [seconds]	Speedup
Baseline	5868	1.00x
Avoid I/O overhead + cKDTree	2233	2.62x
Parallel version 20 CPU	90	65.20x



Hardware:

- MS Azure HDInsight cluster (Ubuntu)
 - 2 headnodes
 - 5 workernodes
 - 4 CPU-cores each
- Intel Xeon® E5-2673 v3 @ 2.40GHz
- Storage: standard LRS (WASB)

Datos:

- >700,000,000 CDRs (1 day, 25~30GB)
- >1500 antennas
- >110,000 user traces

Desafíos: tiempos de cómputo y consulta

Data+Voice raw trace extraction

Pig+Tez (Hadoop)	Time [seconds]	Speedup
Baseline	~1200	1.00x
Bash execution	730	1.64x
Merge in 1 script	234	5.12x
Optimal number of mappers and reducers	150	8.00x
Optimal heap size	140	8.57x
Java UDF	130	9.23x
Compression LZO	?	?

OD matrix estimation using trip analysis

Python+MPI	Time [seconds]	Speedup
Baseline	1516	1.00x
Memoization/Code opt.	485	3.12x
Parallel version 16 CPU	35	42.64x



Hardware:

- MS Azure HDInsight cluster (Ubuntu)
 - 2 headnodes
 - 4 workernodes
 - 4 CPU-cores each
- Intel Xeon® E5-2673 v3 @ 2.40GHz
- Storage: standard LRS (WASB)

Datos:

- >100,000,000 CDRs (1 day, 3~4GB)
- >1000 antennas
- >8,000 user traces

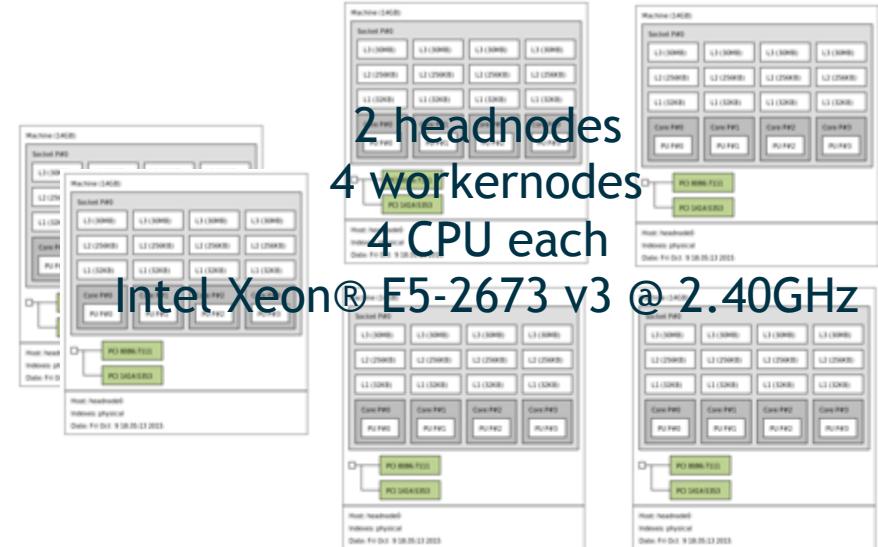
Desafíos: tiempos de cómputo/consulta

Trip analysis

Python+MPI	Time [seconds]	Speedup
Baseline	1516	1.00x
Memoization/code opt.	2233	2.62x
Parallel version 16 CPU	90	65.20x



HDInsight



Intel Xeon® E5-2673 v3 @ 2.40GHz



mamutdeveloper

Storage standard LRS

+700,000,000 CDRs (1 day, 4~5GB)
+1000 antennas
+8,000 user traces

Desafíos: ejecución remota

- ▶ Ejecución de workflows/aplicaciones “lentas” en tiempo real, i.e. usando un cluster de computadores o máquinas virtuales

	Costo	Tiempo de respuesta
Cluster dedicado	Alto	Bajo
Cluster on-demand	Bajo (a medida)*	Alto

- ▶ Apache Oozie: adaptar workflow que usa Hadoop y MPI u otro modelo distribuído a esquema de ejecución desde un servidor Tomcat (Java servlet)

* <https://azure.microsoft.com/es-es/pricing/details/hdinsight/>

Cooperación: MAMUT

MAMUT

Cluster

Jobs

Datasets

Subscriptions

Main Panel

Carlos Guerrero ▾

Jobs

ID	Job Name	Duration	MapReduce Progress	Map	Reduce	Priority	State
job_1449080548701_0001	demo count cdr	2 hours	<div style="width: 100%; background-color: #00A000; height: 10px;"></div>	100 %	100 %	NORMAL	SUCCEEDED